PROPOSAL TUGAS AKHIR

PERANCANGAN DAN EVALUASI SISTEM TANYA JAWAB REGULASI LAHAN SAWIT MENGGUNAKAN HYBRID RETRIEVAL-AUGMENTED GENERATION DAN METADATA FILTERING BERBASIS LARGE LANGUAGE MODEL

DISUSUN OLEH :

DODY SAPUTRA SIMANJORANG 223510777

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS ISLAM RIAU

PEKANBARU

2026

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas berkat dan rahmat-Nya penulis dapat menyelesaikan proposal tugas akhir yang berjudul:

"Perancangan dan Evaluasi Sistem Tanya Jawab Regulasi Lahan Sawit Menggunakan Hybrid Retrieval-Augmented Generation dan Metadata Filtering Berbasis Large Language Model"

Proposal ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan pada Program Studi Teknik Informatika, Fakultas Teknik, Universitas Islam Riau.

Penulis menyadari bahwa proposal ini masih jauh dari kata sempurna. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang membangun demi perbaikan di masa yang akan datang.

Akhir kata, penulis berharap semoga proposal ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya di bidang Artificial Intelligence dan Natural Language Processing.

Pekanbaru, 30 Maret 2026

Dody Saputra Simanjorang

DAFTAR ISI

KATA PENGANTAR ..... **i**
DAFTAR ISI ..... **ii**
BAB I PENDAHULUAN **1**
1.1 Latar Belakang 1
1.2 Identifikasi Masalah 3
1.3 Rumusan Masalah 4
1.4 Batasan Masalah 4
1.5 Manfaat Penelitian 5
DAFTAR PUSTAKA **6**

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perkembangan Artificial Intelligence (AI) dalam satu dekade terakhir mengalami akselerasi yang sangat signifikan, terutama sejak arsitektur Transformer memperlihatkan kemampuan pemodelan bahasa yang lebih efektif dibanding pendekatan sekuensial sebelumnya (Vaswani et al., 2017). Kemajuan tersebut kemudian mendorong lahirnya model bahasa pra-latih berskala besar seperti BERT dan GPT yang secara konsisten meningkatkan performa pada berbagai tugas Natural Language Processing (NLP), termasuk question answering (QA) (Brown et al., 2020; Devlin et al., 2019) Pada konteks QA terbuka, pergeseran dari pencarian berbasis kata kunci semata ke representasi padat (dense retrieval) juga menunjukkan peningkatan yang terukur; misalnya, Dense Passage Retrieval dilaporkan mengungguli sistem BM25 sebesar 9–19% absolut pada akurasi retrieval top-20 di beberapa benchmark QA (Karpukhin et al., 2020). Di sisi lain, benchmark seperti SQuAD turut menegaskan bahwa kebutuhan pengguna bukan hanya "menemukan dokumen", melainkan memperoleh jawaban ringkas, tepat, dan berbasis konteks (Rajpurkar et al., 2016). Tren ini menunjukkan bahwa akses informasi yang cepat dan akurat menjadi kebutuhan kritis pada domain berisiko tinggi, termasuk domain regulasi, karena kualitas keputusan sangat bergantung pada ketepatan interpretasi norma hukum yang dirujuk; dalam konteks Indonesia, urgensi ini semakin nyata pada isu regulasi lahan dan perkebunan sawit yang bersifat multidokumen dan dinamis.

Meskipun kebutuhan terhadap sistem QA hukum semakin tinggi, karakter regulasi lahan sawit di Indonesia menghadirkan persoalan yang kompleks karena aturan tersebar di berbagai tingkatan perundang-undangan—mulai dari undang-undang, peraturan pemerintah, peraturan presiden, hingga peraturan menteri—yang saling beririsan secara terminologi maupun substansi. Pada praktiknya,

pencarian manual terhadap pasal-pasal relevan memerlukan waktu lama, rentan melewatkan dokumen penting, serta menyulitkan integrasi antar sumber hukum ketika pengguna harus menilai isu secara lintas regulasi. Sistem pencarian tradisional berbasis keyword memiliki keterbatasan dalam memahami semantik pertanyaan, sehingga sering menghasilkan temuan yang secara leksikal mirip namun tidak kontekstual terhadap kebutuhan pengguna (Karpukhin et al., 2020). Sebaliknya, penggunaan LLM secara murni tanpa landasan dokumen otoritatif berisiko menghasilkan hallucination, yaitu keluaran yang tampak meyakinkan tetapi tidak didukung sumber hukum yang valid (Ji et al., 2023). Tantangan menjadi semakin besar karena dokumen regulasi umumnya panjang, semi-terstruktur, serta memerlukan pemilahan berbasis metadata seperti tahun, jenis regulasi, dan instansi penerbit agar hasil temu-kembali lebih presisi; kondisi ini sejalan dengan temuan bahwa pemodelan bahasa domain hukum membutuhkan adaptasi khusus dan tidak selalu dapat mengandalkan model umum secara langsung (Chalkidis et al., 2020). Apabila permasalahan tersebut tidak ditangani secara sistematis, dampaknya dapat berupa kesalahan interpretasi regulasi, lambatnya proses pengambilan keputusan, dan meningkatnya risiko ketidakpatuhan hukum pada tata kelola lahan perkebunan.

Berdasarkan permasalahan tersebut, penelitian ini menawarkan pendekatan Hybrid Retrieval-Augmented Generation (Hybrid RAG) untuk membangun sistem tanya jawab regulasi lahan sawit yang lebih andal. Secara konseptual, RAG menggabungkan dua tahap utama: retrieval untuk mengambil konteks dari basis pengetahuan, dan generation untuk menyusun jawaban berbasis konteks menggunakan LLM, sehingga keluaran model lebih terikat pada evidensi dokumen (Lewis et al., 2020). Dalam penelitian ini, retrieval dirancang secara hibrida dengan mengombinasikan semantic search berbasis embedding dense dan keyword search (misalnya BM25) agar sistem mampu menangkap kemiripan makna sekaligus ketepatan istilah hukum (Karpukhin et al., 2020; Reimers & Gurevych, 2019). Untuk meningkatkan relevansi, diterapkan pula metadata filtering pada tahap awal retrieval—misalnya berdasarkan jenis regulasi, tahun

terbit, dan instansi—sehingga ruang pencarian menjadi lebih terfokus terhadap konteks pertanyaan. Selain itu, dukungan teknologi seperti vector database untuk pencarian kemiripan cepat dan mekanisme reranking untuk memprioritaskan kandidat paling relevan memperkuat kualitas hasil akhir (Gao et al., 2024; Nogueira & Cho, 2020). Dengan demikian, kontribusi penelitian ini terletak pada perancangan arsitektur sistem QA regulasi lahan sawit berbasis Hybrid RAG dan metadata filtering, serta evaluasi performa sistem untuk menilai peningkatan akurasi, relevansi, dan keandalan jawaban pada skenario penggunaan nyata.

1.2 Identifikasi Masalah

Berdasarkan latar belakang, masalah yang dapat diidentifikasi adalah sebagai berikut:

1. Belum tersedianya mekanisme integrasi regulasi lahan sawit yang komprehensif dari berbagai sumber hukum (UU, PP, Perpres, dan Permen), sehingga penelusuran ketentuan lintas dokumen masih tersebar dan tidak efisien.
2. Keterbatasan sistem pencarian informasi tradisional berbasis kata kunci yang cenderung mengandalkan kecocokan leksikal, sehingga hasil pencarian sering kurang kontekstual terhadap maksud pertanyaan pengguna.
3. Keterbatasan pemanfaatan Large Language Model (LLM) secara mandiri tanpa proses retrieval berbasis dokumen resmi, yang berpotensi menghasilkan hallucination dan jawaban yang tidak memiliki dasar regulatif yang valid.
4. Kurangnya penerapan pendekatan Hybrid Retrieval-Augmented Generation (Hybrid RAG) pada domain regulasi lahan sawit, khususnya untuk menggabungkan keunggulan semantic retrieval dan keyword retrieval dalam satu alur tanya jawab hukum.
5. Keterbatasan penggunaan metadata dokumen regulasi (jenis regulasi, tahun terbit, dan instansi penerbit) dalam proses temu-kembali, yang berdampak pada rendahnya relevansi hasil, lambatnya akses informasi, serta

meningkatnya potensi kesalahan interpretasi oleh pengguna.

1.3 Rumusan Masalah

Rumusan masalah dalam penelitian ini adalah:

1. Bagaimana merancang sistem tanya jawab regulasi lahan sawit yang mampu menelusuri dan menyajikan informasi hukum secara kontekstual melalui pendekatan Hybrid Retrieval-Augmented Generation?
2. Bagaimana pengaruh penerapan kombinasi semantic search dan keyword-based retrieval terhadap relevansi dokumen rujukan serta ketepatan jawaban yang dihasilkan oleh Large Language Model?
3. Bagaimana pemanfaatan metadata filtering (jenis regulasi, tahun, dan instansi) berkontribusi terhadap peningkatan presisi pencarian dan keandalan jawaban pada sistem tanya jawab regulasi lahan sawit?

1.4 Batasan Masalah

Batasan masalah pada penelitian ini meliputi:

1. Penelitian ini dibatasi pada pengembangan sistem tanya jawab untuk domain regulasi lahan sawit di Indonesia, bukan untuk seluruh domain hukum nasional.
2. Sistem yang dibangun hanya menggunakan pendekatan Hybrid Retrieval-Augmented Generation, yaitu kombinasi semantic search berbasis embedding dan keyword-based retrieval.
3. Komponen generatif pada sistem dibatasi pada penggunaan Large Language Model sebagai penyusun jawaban berbasis konteks dokumen yang berhasil di-retrieve.
4. Data penelitian ini dibatasi pada kumpulan dokumen regulasi terpilih yang relevan dengan lahan sawit (antara lain UU, Perpres, dan Permen), sesuai korpus yang dikurasi dalam penelitian.
5. Penelitian ini dibatasi pada penerapan metadata filtering berdasarkan atribut tertentu (misalnya jenis regulasi, tahun, dan instansi) serta evaluasi sistem

pada aspek ketepatan jawaban dan relevansi hasil retrieval melalui pengujian terukur/uji manual terbatas.

1.5 Manfaat Penelitian

Manfaat penelitian ini adalah:

1. Memberikan kontribusi teoritis pada pengembangan keilmuan Artificial Intelligence dan Natural Language Processing, khususnya pada penerapan Hybrid Retrieval-Augmented Generation untuk sistem tanya jawab domain hukum.
2. Menjadi referensi akademik bagi penelitian lanjutan terkait integrasi semantic retrieval, keyword-based retrieval, dan metadata filtering pada pengolahan dokumen regulasi.
3. Membantu pengguna memperoleh informasi regulasi lahan sawit secara lebih cepat, terarah, dan berbasis sumber dokumen yang relevan.
4. Meningkatkan kualitas akses informasi hukum melalui penyajian jawaban yang lebih kontekstual, sehingga dapat menekan potensi kesalahan interpretasi regulasi.
5. Menjadi acuan praktis bagi pengembang sistem dan instansi terkait dalam membangun layanan tanya jawab regulasi untuk mendukung analisis dan pengambilan keputusan berbasis aturan.

DAFTAR PUSTAKA

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., … Amodei, D. (2020). *Language Models are Few-Shot Learners*. https://commoncrawl.org/the-data/

Chalkidis, I., Fergadiotis, M., Malakasiotis, P., & Aletras, N. (2020). *Findings of the Association for Computational Linguistics LEGAL-BERT: The Muppets straight out of Law School*. http://www.legislation.gov.uk

Devlin, J., Chang, M.-W., Lee, K., Google, K. T., & Language, A. I. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. https://github.com/tensorflow/tensor2tensor

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). *Retrieval-Augmented Generation for Large Language Models: A Survey*. http://arxiv.org/abs/2312.10997

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Chen, D., Dai, W., Chan, H. S., Madotto, A., & Fung, P. (2023). *Survey of Hallucination in Natural Language Generation*. https://doi.org/10.1145/3571730

Karpukhin, V., O˘ Guz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., Yih, W.-T., & Ai, F. (2020). *Dense Passage Retrieval for Open-Domain Question Answering*. https://github.com/facebookresearch/DPR.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. https://github.com/huggingface/transformers/blob/master/

Nogueira, R., & Cho, K. (2020). *Passage Re-ranking with BERT*. http://arxiv.org/abs/1901.04085

Rajpurkar, P., Zhang, J., Lopyrev, K., & Liang, P. (2016). *SQuAD: 100,000+ Questions for Machine Comprehension of Text*. https://stanford-qa.com,

Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using*

Siamese BERT-Networks. https://github.com/UKPLab/

Vaswani, A., Brain, G., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention Is All You Need*.