TUGAS AKHIR

PERANCANGAN DAN EVALUASI SISTEM TANYA JAWAB REGULASI LAHAN SAWIT MENGGUNAKAN HYBRID RETRIEVAL-AUGMENTED GENERATION DAN METADATA FILTERING BERBASIS LARGE LANGUAGE MODEL

DODY SAPUTRA SIMANJORANG

223510777

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS ISLAM RIAU

PEKANBARU

2026

KATA PENGANTAR

Puji syukur Penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat dan penyertaan-Nya, sehingga Penulis dapat menyelesaikan skripsi ini dengan baik. Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan studi pada program sarjana, sekaligus sebagai bentuk tanggung jawab akademik Penulis dalam mengembangkan pengetahuan dan menerapkan ilmu yang telah diperoleh selama perkuliahan. Dalam proses penyusunannya, Penulis berusaha menyajikan pembahasan yang sistematis dan relevan dengan topik penelitian yang diangkat, yaitu mengenai perancangan dan evaluasi sistem tanya jawab regulasi lahan sawit menggunakan pendekatan hybrid retrieval-augmented generation dan metadata filtering berbasis large language model.

Penulis menyadari bahwa penyusunan skripsi ini tidak terlepas dari berbagai keterbatasan dan tantangan. Oleh karena itu, Penulis mengucapkan terima kasih kepada semua pihak yang telah memberikan dukungan, baik berupa doa, semangat, maupun bantuan dalam bentuk lain selama proses penyusunan skripsi ini. Penulis juga berharap skripsi ini dapat memberikan manfaat bagi pembaca, khususnya sebagai referensi dalam pengembangan sistem tanya jawab berbasis kecerdasan buatan serta penelitian sejenis di masa mendatang.

Penulis menyadari bahwa skripsi ini masih memiliki kekurangan. Oleh karena itu, Penulis sangat terbuka terhadap kritik dan saran yang membangun demi perbaikan di masa yang akan datang. Akhir kata, Penulis berharap semoga skripsi ini dapat memberikan kontribusi yang bermanfaat bagi pengembangan ilmu pengetahuan

DAFTAR ISI

KATA PENGANTAR ii
Daftar Gambar vi
DAFTAR TABEL vii
BAB I PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Identifikasi Masalah 3
1.3 Rumusan Masalah 4
1.4 Batasan Masalah 4
1.5 Tujuan Penelitian 5
1.6 Manfaat Penelitian 5
BAB II LANDASAN TEORI 6
2.1 Tinjauan Pustaka 6
2.1.1 Perkembangan Dasar NLP dan Large Language Model 12
2.1.2 Penelitian Retrieval pada Sistem Question Answering 13
2.1.3 Penelitian Re-ranking sebagai Penguat Tahap Retrieval 14
2.1.4 Penelitian Retrieval-Augmented Generation (RAG) 14
2.1.5 Penelitian Evaluasi Retrieval Lintas Domain 15
2.2 Dasar Teori 15
2.2.1 Kecerdasan Buatan (Artificial Intelligence) 15
2.2.2 Pemrosesan Bahasa Alami (Natural Language Processing) 16
2.2.3 Large Language Model (LLM) 16
2.2.4 Sistem Tanya Jawab (Question Answering System) 17
2.2.5 Information Retrieval: Sparse dan Dense Retrieval 17
2.2.6 Passage Re-ranking 17
2.2.7 Retrieval-Augmented Generation (RAG) 18
2.2.8 Hybrid Retrieval 18
2.2.9 Metadata Filtering pada Dokumen Regulasi 18
2.2.10 Landasan Evaluasi Sistem QA Berbasis RAG 19
2.3 Kerangka Pemikiran 19
BAB III METODE PENELITIAN 26
3.1 Jenis dan Pendekatan Penelitian 26
3.2 Objek Penelitian 27

3.3 Data Penelitian 29
3.3.1 Identifikasi Kebutuhan Data Regulasi 31
3.3.2 Pengumpulan Dokumen Regulasi (PDF) 31
3.3.3 Seleksi Dokumen Relevan 31
3.3.4 Validasi Dokumen 32
3.3.5 Ekstraksi Teks dari PDF 32
3.3.6 Pembersihan Teks (Cleaning) 32
3.3.7 Chunking Dokumen per Pasal/Ayat 33
3.3.8 Penambahan Metadata 33
3.3.9 Validasi Hasil Chunk dan Metadata 33
3.3.10 Dataset Siap untuk Indexing dan Evaluasi 34
3.4 Tahapan Penelitian 34
3.4.1 Dasar Ilmiah (Studi Literatur & Perumusan Masalah) 38
3.4.2 Data Akuisisi (Pengumpulan & Seleksi Dokumen) 38
3.4.3 Preprocessing (Ekstraksi, Cleaning & Normalisasi) 38
3.4.4 Data Structuring (Chunking & Penyusunan Metadata) 39
3.4.5 Basis Retrieval (Embedding, Qdrant & BM25) 39
3.4.6 Integrasi Modul (Hybrid Retrieval & Metadata Filter) 40
3.4.7 Pipeline RAG (Context Builder, LLM & Tanya Jawab) 40
3.4.8 Uji Eksperimental (Scenario Testing) 41
3.4.9 Analisis Performa (Evaluasi Metrik & Hasil) 41
3.4.10 Sintesis Akhir (Kesimpulan & Rekomendasi) 42
3.5 Perancangan Sistem 42
3.5.1 Input Pertanyaan Bahasa Alami 46
3.5.2 Metadata Filtering (Extraction) 46
3.5.3 Hybrid Retrieval (Semantic & Lexical Search) 46
3.5.4 RRF Fusion (Scoring & Re-ranking) 47
3.5.5 Penentuan Konteks Top-K 47
3.5.6 Generasi Jawaban menggunakan LLM 48
3.5.7 Jawaban dan Sumber Rujukan 48
3.8 Lingkungan Implementasi 49
3.9 Teknik Analisis Hasil 51
DAFTAR PUSTAKA 53

Daftar Gambar

Gambar 2. 1 Diagram Kerangka Pemikiran 22
Gambar 3. 1 Alur Pengumpulan dan Persiapan Data 30
Gambar 3. 2 Flowchart Tahapan Penelitian End-to-End 37
Gambar 3. 3 Pipeline Metode yang Diusulkan 45

DAFTAR TABEL

Tabel 2. 1 Tinjauan Pustaka 9
Tabel 3. 1 Ruang Lingkup Objek Penelitian 28
Tabel 3. 2 Daftar Dokumen Regulasi yang Digunakan 29
Tabel 3. 3 Statistik Data Penelitian 29
Tabel 3. 4 Ringkasan Tiap Tahap Penelitian 35
Tabel 3. 5 Parameter Sistem 43
Tabel 3. 6 Atribut dan Aturan Metadata Filtering 48
Tabel 3. 7 Spesifikasi Hardware 49
Tabel 3. 8 Software, Framework, dan Library yang Digunakan 50
Tabel 3. 9 Kriteria Interpretasi Nilai Metrik 52

BAB I
PENDAHULUAN

1.1 Latar Belakang

Perkembangan Artificial Intelligence (AI) dalam satu dekade terakhir mengalami akselerasi yang sangat signifikan, terutama sejak arsitektur Transformer memperlihatkan kemampuan pemodelan bahasa yang lebih efektif dibanding pendekatan sekuensial sebelumnya (Vaswani et al., 2017). Kemajuan tersebut kemudian mendorong lahirnya model bahasa pra-latih berskala besar seperti BERT dan GPT yang secara konsisten meningkatkan performa pada berbagai tugas Natural Language Processing (NLP), termasuk question answering (QA) (Brown et al., 2020; Devlin et al., 2019) Pada konteks QA terbuka, pergeseran dari pencarian berbasis kata kunci semata ke representasi padat (dense retrieval) juga menunjukkan peningkatan yang terukur; misalnya, Dense Passage Retrieval dilaporkan mengungguli sistem BM25 sebesar 9–19% absolut pada akurasi retrieval top-20 di beberapa benchmark QA (Karpukhin et al., 2020). Di sisi lain, benchmark seperti SQuAD turut menegaskan bahwa kebutuhan pengguna bukan hanya "menemukan dokumen", melainkan memperoleh jawaban ringkas, tepat, dan berbasis konteks (Rajpurkar et al., 2016). Tren ini menunjukkan bahwa akses informasi yang cepat dan akurat menjadi kebutuhan kritis pada domain berisiko tinggi, termasuk domain regulasi, karena kualitas keputusan sangat bergantung pada ketepatan interpretasi norma hukum yang dirujuk; dalam konteks Indonesia, urgensi ini semakin nyata pada isu regulasi lahan dan perkebunan sawit yang bersifat multidokumen dan dinamis.

Meskipun kebutuhan terhadap sistem QA hukum semakin tinggi, karakter regulasi lahan sawit di Indonesia menghadirkan persoalan yang kompleks karena aturan tersebar di berbagai tingkatan perundang-undangan—mulai dari undang-undang, peraturan pemerintah, peraturan presiden, hingga peraturan menteri—yang saling beririsan secara terminologi maupun substansi. Pada praktiknya, pencarian manual terhadap pasal-pasal relevan memerlukan waktu lama, rentan

melewatkan dokumen penting, serta menyulitkan integrasi antar sumber hukum ketika pengguna harus menilai isu secara lintas regulasi. Sistem pencarian tradisional berbasis keyword memiliki keterbatasan dalam memahami semantik pertanyaan, sehingga sering menghasilkan temuan yang secara leksikal mirip namun tidak kontekstual terhadap kebutuhan pengguna (Karpukhin et al., 2020). Sebaliknya, penggunaan LLM secara murni tanpa landasan dokumen otoritatif berisiko menghasilkan hallucination, yaitu keluaran yang tampak meyakinkan tetapi tidak didukung sumber hukum yang valid (Ji et al., 2024). Tantangan menjadi semakin besar karena dokumen regulasi umumnya panjang, semi-terstruktur, serta memerlukan pemilahan berbasis metadata seperti tahun, jenis regulasi, dan instansi penerbit agar hasil temu-kembali lebih presisi; kondisi ini sejalan dengan temuan bahwa pemodelan bahasa domain hukum membutuhkan adaptasi khusus dan tidak selalu dapat mengandalkan model umum secara langsung (Chalkidis et al., 2020). Apabila permasalahan tersebut tidak ditangani secara sistematis, dampaknya dapat berupa kesalahan interpretasi regulasi, lambatnya proses pengambilan keputusan, dan meningkatnya risiko ketidakpatuhan hukum pada tata kelola lahan perkebunan.

Berdasarkan permasalahan tersebut, penelitian ini menawarkan pendekatan Hybrid Retrieval-Augmented Generation (Hybrid RAG) untuk membangun sistem tanya jawab regulasi lahan sawit yang lebih andal. Secara konseptual, RAG menggabungkan dua tahap utama: retrieval untuk mengambil konteks dari basis pengetahuan, dan generation untuk menyusun jawaban berbasis konteks menggunakan LLM, sehingga keluaran model lebih terikat pada evidensi dokumen (Lewis et al., 2020). Dalam penelitian ini, retrieval dirancang secara hibrida dengan mengombinasikan semantic search berbasis embedding dense dan keyword search (misalnya BM25) agar sistem mampu menangkap kemiripan makna sekaligus ketepatan istilah hukum (Karpukhin et al., 2020; Reimers & Gurevych, 2019). Untuk meningkatkan relevansi, diterapkan pula metadata filtering pada tahap awal retrieval—misalnya berdasarkan jenis regulasi, tahun terbit, dan instansi—sehingga ruang pencarian menjadi lebih terfokus terhadap

konteks pertanyaan. Selain itu, dukungan teknologi seperti vector database untuk pencarian kemiripan cepat dan mekanisme reranking untuk memprioritaskan kandidat paling relevan memperkuat kualitas hasil akhir (Gao et al., 2024; Nogueira & Cho, 2020). Dengan demikian, kontribusi penelitian ini terletak pada perancangan arsitektur sistem QA regulasi lahan sawit berbasis Hybrid RAG dan metadata filtering, serta evaluasi performa sistem untuk menilai peningkatan akurasi, relevansi, dan keandalan jawaban pada skenario penggunaan nyata.

1.2 Identifikasi Masalah

Berdasarkan latar belakang, masalah yang dapat diidentifikasi adalah sebagai berikut:

1. Belum tersedianya mekanisme integrasi regulasi lahan sawit yang komprehensif dari berbagai sumber hukum (UU, PP, Perpres, dan Permen), sehingga penelusuran ketentuan lintas dokumen masih tersebar dan tidak efisien.
2. Keterbatasan sistem pencarian informasi tradisional berbasis kata kunci yang cenderung mengandalkan kecocokan leksikal, sehingga hasil pencarian sering kurang kontekstual terhadap maksud pertanyaan pengguna.
3. Keterbatasan penggunaan Large Language Model (LLM) tanpa dukungan mekanisme retrieval berbasis dokumen regulasi resmi, sehingga jawaban yang dihasilkan berisiko mengalami hallucination, kurang akurat secara substansi hukum, dan tidak memiliki landasan regulatif yang dapat diverifikasi.
4. Kurangnya penerapan pendekatan Hybrid Retrieval-Augmented Generation (Hybrid RAG) pada domain regulasi lahan sawit, khususnya untuk menggabungkan keunggulan semantic retrieval dan keyword retrieval dalam satu alur tanya jawab hukum.
5. Keterbatasan penggunaan metadata dokumen regulasi (jenis regulasi, tahun terbit, dan instansi penerbit) dalam proses temu-kembali, yang berdampak pada rendahnya relevansi hasil, lambatnya akses informasi, serta meningkatnya potensi kesalahan interpretasi oleh pengguna.

1.3 Rumusan Masalah

Rumusan masalah dalam penelitian ini adalah:

1. Bagaimana merancang sistem tanya jawab regulasi lahan sawit yang mampu menelusuri dan menyajikan informasi hukum secara kontekstual melalui pendekatan Hybrid Retrieval-Augmented Generation?
2. Bagaimana pengaruh penerapan kombinasi semantic search dan keyword-based retrieval terhadap relevansi dokumen rujukan serta ketepatan jawaban yang dihasilkan oleh Large Language Model?
3. Bagaimana pemanfaatan metadata filtering (jenis regulasi, tahun, dan instansi) berkontribusi terhadap peningkatan presisi pencarian dan keandalan jawaban pada sistem tanya jawab regulasi lahan sawit?

1.4 Batasan Masalah

Batasan masalah pada penelitian ini meliputi:

1. Penelitian ini dibatasi pada pengembangan sistem tanya jawab untuk domain regulasi lahan sawit di Indonesia, bukan untuk seluruh domain hukum nasional.
2. Sistem yang dibangun hanya menggunakan pendekatan Hybrid Retrieval-Augmented Generation, yaitu kombinasi semantic search berbasis embedding dan keyword-based retrieval.
3. Komponen generatif pada sistem dibatasi pada penggunaan Large Language Model sebagai penyusun jawaban berbasis konteks dokumen yang berhasil di-retrieve.
4. Data penelitian ini dibatasi pada kumpulan dokumen regulasi terpilih yang relevan dengan lahan sawit (antara lain UU, Perpres, dan Permen), sesuai korpus yang dikurasi dalam penelitian.
5. Penelitian ini dibatasi pada penerapan metadata filtering berdasarkan atribut tertentu (misalnya jenis regulasi, tahun, dan instansi) serta evaluasi sistem pada aspek ketepatan jawaban dan relevansi hasil retrieval melalui pengujian

terukur/uji manual terbatas.

1.5 Tujuan Penelitian

Tujuan penelitian ini adalah :

1. Merancang dan membangun sistem tanya jawab regulasi lahan sawit berbasis Hybrid Retrieval-Augmented Generation yang mampu menyajikan jawaban kontekstual dengan rujukan dokumen yang relevan.
2. Menganalisis pengaruh kombinasi semantic search dan keyword-based retrieval terhadap peningkatan relevansi dokumen hasil temu-kembali serta ketepatan jawaban yang dihasilkan sistem.
3. Mengevaluasi kontribusi metadata filtering (jenis regulasi, tahun, dan instansi) dalam meningkatkan presisi pencarian, keandalan jawaban, dan kemudahan penelusuran informasi regulasi.

1.6 Manfaat Penelitian

Manfaat penelitian ini adalah:

1. Sebagai manfaat dari tujuan perancangan sistem, penelitian ini menghasilkan rancangan dan implementasi sistem tanya jawab regulasi lahan sawit berbasis Hybrid RAG yang dapat menjadi kontribusi praktis sekaligus referensi teknis untuk pengembangan sistem serupa pada domain hukum.
2. Sebagai manfaat dari tujuan analisis kombinasi semantic dan keyword retrieval, penelitian ini memberikan bukti empiris mengenai pendekatan retrieval yang lebih efektif untuk meningkatkan relevansi dokumen dan ketepatan jawaban.
3. Sebagai manfaat dari tujuan evaluasi metadata filtering, penelitian ini menunjukkan bahwa penyaringan berbasis jenis regulasi, tahun, dan instansi dapat mempercepat penelusuran informasi, meningkatkan presisi hasil, serta membantu pengguna memperoleh jawaban yang lebih andal dan mudah diverifikasi.

BAB II
LANDASAN TEORI

2.1 Tinjauan Pustaka

Perkembangan sistem tanya jawab berbasis kecerdasan buatan tidak dapat dilepaskan dari lompatan metodologis pada pemrosesan bahasa alami, terutama setelah diperkenalkannya arsitektur Transformer yang memungkinkan pemodelan dependensi konteks secara lebih efektif pada data teks berskala besar(Vaswani et al., 2017). Fondasi ini kemudian diperkuat oleh model pra-latih seperti BERT yang menunjukkan peningkatan signifikan pada berbagai tugas NLP, termasuk question answering, karena kemampuan representasi kontekstual dua arah yang lebih kaya dibanding pendekatan sebelumnya (Devlin et al., 2019). Pada tahap ini, penelitian-penelitian awal menegaskan bahwa kualitas pemahaman bahasa mesin sangat menentukan keberhasilan sistem tanya jawab, tetapi belum sepenuhnya menjawab isu keandalan fakta pada domain yang menuntut presisi tinggi, seperti regulasi dan hukum.

Dalam ranah open-domain question answering, meneliti kelemahan retrieval berbasis kata kunci dengan mengembangkan Dense Passage Retrieval (DPR). Penelitian tersebut bertujuan meningkatkan kemampuan sistem dalam menemukan dokumen relevan walaupun terjadi perbedaan bentuk leksikal antara pertanyaan dan dokumen sumber. Metode dual-encoder yang digunakan memetakan query dan passage ke ruang embedding yang sama, lalu menghitung relevansi berdasarkan kesamaan vektor. Hasilnya memperlihatkan peningkatan top-20 retrieval accuracy secara absolut sebesar 9–19% dibanding BM25 pada beberapa benchmark QA (Karpukhin et al., 2020). Temuan ini penting karena menunjukkan bahwa pencarian semantik dapat mengatasi keterbatasan pencocokan kata literal; namun, studi ini masih berfokus pada benchmark umum dan belum diarahkan pada dokumen hukum Indonesia yang panjang serta berstruktur pasal.

Berikutnya, menyoroti bahwa kualitas retrieval tidak hanya ditentukan oleh kemampuan menemukan kandidat dokumen, tetapi juga oleh urutan prioritas konteks yang diberikan ke modul penjawab. Tujuan penelitian mereka adalah meningkatkan

relevansi dokumen teratas melalui passage re-ranking berbasis BERT. Metode yang digunakan berupa fine-tuning model untuk menilai pasangan query-passage secara lebih mendalam daripada pendekatan skor tradisional. Hasil penelitian menunjukkan perbaikan performa retrieval yang konsisten, menegaskan bahwa tahap re-ranking berkontribusi langsung pada kualitas jawaban akhir (Nogueira & Cho, 2020). Dalam konteks penelitian regulasi lahan sawit, implikasinya adalah bahwa sistem QA membutuhkan desain retrieval bertingkat agar pasal yang paling relevan benar-benar berada di konteks teratas.

Kemajuan yang lebih komprehensif ditunjukkan oleh melalui arsitektur Retrieval-Augmented Generation (RAG), yang secara eksplisit menggabungkan retriever dan generator dalam satu alur kerja untuk tugas knowledge-intensive NLP. Tujuan utama penelitian ini adalah mengurangi ketergantungan model generatif terhadap memori parametrik semata dengan menyuntikkan bukti dari korpus eksternal saat inferensi. Metode RAG memanfaatkan pengambilan dokumen relevan terlebih dahulu, kemudian menggunakan dokumen tersebut sebagai konteks untuk pembangkitan jawaban. Hasil eksperimen memperlihatkan peningkatan kinerja dibanding model generatif murni pada berbagai tugas yang membutuhkan ketepatan pengetahuan faktual (Lewis et al., 2020). Relevansi bagi skripsi ini sangat kuat, karena domain regulasi menuntut jawaban yang dapat ditelusuri sumber pasalnya, bukan sekadar respons yang fasih secara bahasa.

Meskipun demikian, generalisasi retrieval lintas domain tidak selalu linear. Melalui benchmark BEIR menunjukkan bahwa tidak ada satu paradigma retrieval yang selalu dominan pada semua jenis korpus. Tujuan penelitian tersebut adalah mengevaluasi robustitas model sparse, dense, dan metode turunannya dalam skenario zero-shot pada kumpulan dataset heterogen. Hasilnya menunjukkan dense retrieval sering unggul, tetapi sparse retrieval tetap kompetitif pada domain tertentu, khususnya yang kaya istilah eksplisit dan struktur terminologis formal (Thakur et al., 2021). Temuan ini memberikan landasan metodologis bagi pendekatan hybrid retrieval, karena kombinasi semantic search dan keyword-based search berpotensi

memberi keseimbangan antara pemahaman makna dan ketepatan istilah normatif.

Pada domain hukum, mengembangkan LEGAL-BERT untuk menjawab kebutuhan representasi bahasa yang lebih sesuai dengan karakter teks legal. Tujuan studi ini adalah menguji apakah adaptasi domain mampu meningkatkan performa model dibanding model general-purpose. Metode yang diterapkan meliputi domain-adaptive pretraining dan evaluasi pada berbagai tugas legal NLP. Hasilnya menegaskan bahwa model berbasis korpus hukum memberikan peningkatan pada sejumlah task, sekaligus menunjukkan bahwa transfer langsung dari model umum tidak selalu optimal untuk domain legal(Chalkidis et al., 2020). Namun, penelitian tersebut lebih menekankan aspek representasi bahasa, belum memfokuskan diri pada sistem QA regulasi end-to-end yang mengintegrasikan retrieval, filtering, generation, dan sitasi sumber.

Persoalan lain yang krusial adalah keandalan faktual jawaban LLM. Meninjau secara sistematis fenomena hallucination pada natural language generation dan menemukan bahwa model bahasa tetap berisiko menghasilkan pernyataan yang tidak didukung bukti sumber, terutama pada domain berisiko tinggi seperti hukum. Tujuan penelitian ini adalah memetakan tipe hallucination, faktor penyebab, dan strategi mitigasi. Hasil kajian menekankan perlunya mekanisme grounding berbasis sumber agar keluaran model lebih dapat dipertanggungjawabkan (Ji et al., 2024). Dari perspektif sistem tanya jawab regulasi lahan sawit, temuan ini memperkuat argumen bahwa penggunaan LLM tanpa retrieval dokumen resmi berpotensi menimbulkan kesalahan interpretasi kebijakan.

Perkembangan mutakhir yang merangkum arah riset ini disajikan oleh melalui survei RAG untuk large language models. Tujuan studi tersebut adalah memetakan komponen kritis RAG—mulai dari indexing, chunking, retrieval, reranking, context construction, hingga evaluasi. Hasilnya menunjukkan bahwa performa sistem tidak ditentukan oleh model generatif saja, melainkan oleh kualitas desain pipeline secara

menyeluruh, termasuk strategi penyaringan konteks sebelum generasi (Gao et al., 2024). Implikasi langsung bagi penelitian ini adalah pentingnya metadata filtering sebagai mekanisme pengendalian ruang pencarian agar konteks yang disuplai ke LLM benar-benar relevan dengan jenis regulasi, tahun, dan instansi yang terkait pertanyaan pengguna.

Berdasarkan sintesis penelitian terdahulu, dapat diidentifikasi beberapa gap yang belum sepenuhnya terjawab. Pertama, sebagian besar penelitian dilakukan pada benchmark global dan belum fokus pada korpus regulasi lahan sawit Indonesia yang bersifat lintas hierarki (UU, PP, Perpres, Permen) dan lintas instansi. Kedua, studi RAG yang ada umumnya menekankan integrasi retrieval-generation, tetapi belum banyak yang secara eksplisit memusatkan desain pada metadata filtering legal-domain sebagai komponen utama relevansi. Ketiga, studi legal NLP telah memperlihatkan pentingnya domain adaptation, namun masih terbatas pada evaluasi task NLP tertentu, bukan pada implementasi sistem QA regulasi end-to-end yang menuntut jawaban bersumber. Dengan demikian, posisi penelitian ini berada pada penguatan state-of-the-art terapan: merancang dan mengevaluasi sistem tanya jawab regulasi lahan sawit berbasis Hybrid RAG (semantic + keyword retrieval), dipadukan dengan metadata filtering untuk meningkatkan ketepatan retrieval, relevansi jawaban, dan keterlacakan rujukan hukum.

Tabel 2. 1 Tinjauan Pustaka

Nama Penulis	**Tahun**	**Judul Penelitian**	**Metode**	**Kesimpulan**
Vaswani et al.	2017	*Attention Is All You Need*	Mengusulkan arsitektur Transformer berbasis self-attention untuk pemodelan urutan	Transformer meningkatkan efektivitas pemodelan dependensi konteks

			tanpa RNN.	pada teks berskala besar dan menjadi fondasi utama perkembangan NLP modern.
Devlin et al.	2019	*BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*	Pre-training bidirectional language model (BERT) dan fine-tuning pada berbagai tugas NLP, termasuk question answering.	BERT menunjukkan peningkatan signifikan pada beragam tugas NLP; representasi kontekstual dua arah terbukti memperkuat kinerja sistem QA.
Karpukhin et al.	2020	*Dense Passage Retrieval for Open-Domain Question Answering*	Dual-encoder dense retrieval yang memetakan query dan passage ke ruang embedding yang sama.	DPR meningkatkan top-20 retrieval accuracy sebesar 9–19% absolut dibanding BM25 pada beberapa benchmark QA, sehingga efektif mengatasi keterbatasan pencocokan kata literal.
Nogueira & Cho	2019	*Passage Re-ranking with*	Fine-tuning BERT untuk re-ranking	Re-ranking berbasis BERT

		BERT	pasangan query–passage setelah tahap retrieval awal.	meningkatkan relevansi dokumen teratas secara konsisten dan berkontribusi langsung pada kualitas jawaban akhir.
Lewis et al.	2020	*Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*	Mengintegrasikan retriever dan generator dalam arsitektur RAG; dokumen relevan diambil terlebih dahulu lalu digunakan sebagai konteks generasi.	RAG meningkatkan kinerja dibanding model generatif murni pada tugas yang menuntut ketepatan pengetahuan faktual.
Thakur et al.	2021	*BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models*	Evaluasi zero-shot lintas dataset heterogen terhadap model sparse, dense, dan turunannya.	Tidak ada paradigma retrieval yang selalu unggul di semua korpus; dense sering unggul, tetapi sparse tetap kompetitif pada domain tertentu.
Chalkidis et al.	2020	*LEGAL-BERT: The Muppets Straight Out of*	Domain-adaptive pretraining pada korpus legal dan	Adaptasi domain legal meningkatkan performa pada

		Law School	evaluasi pada berbagai tugas legal NLP.	sejumlah tugas; model general-purpose tidak selalu optimal untuk teks hukum.
Ji et al.	2023	*Survey of Hallucination in Natural Language Generation*	Tinjauan sistematis tentang tipe, penyebab, dan mitigasi hallucination pada NLG/LLM.	LLM tetap berisiko menghasilkan informasi tanpa dukungan bukti; grounding berbasis sumber diperlukan untuk meningkatkan keandalan keluaran.
Gao et al.	2023	*Retrieval-Augmented Generation for Large Language Models: A Survey*	Survei komprehensif komponen RAG: indexing, chunking, retrieval, reranking, context construction, dan evaluasi.	Kinerja RAG ditentukan oleh kualitas desain pipeline secara menyeluruh, bukan hanya model generatif; penyaringan konteks sebelum generasi sangat penting.

2.1.1 Perkembangan Dasar NLP dan Large Language Model

Perkembangan Artificial Intelligence (AI) dalam dekade terakhir mengalami akselerasi yang sangat tinggi, terutama sejak adopsi arsitektur berbasis Transformer

yang mampu memproses dependensi konteks secara lebih efektif dibanding pendekatan sekuensial klasik (Vaswani et al., 2017). Kemajuan ini mendorong lompatan kinerja pada berbagai tugas Natural Language Processing (NLP), seperti klasifikasi teks, ekstraksi informasi, dan question answering. Salah satu tonggak penting adalah munculnya model bahasa pra-latih berskala besar seperti BERT yang menunjukkan peningkatan signifikan pada benchmark pemahaman bahasa, termasuk machine reading comprehension (Devlin et al., 2019). Selanjutnya, model skala besar seperti GPT memperluas kemampuan model ke skenario few-shot dan zero-shot, sehingga sistem dapat merespons pertanyaan kompleks dengan adaptasi minimal terhadap tugas spesifik (Brown et al., 2020).

Meski demikian, peningkatan kemampuan generatif tidak serta-merta menjamin validitas faktual, khususnya pada domain dengan tingkat risiko kesalahan tinggi seperti hukum dan regulasi. Kemampuan model untuk menghasilkan teks yang koheren sering kali lebih cepat berkembang dibanding kemampuan verifikasi faktual terhadap sumber primer. Oleh sebab itu, literatur mutakhir menekankan bahwa sistem QA modern perlu mengombinasikan kemampuan pemahaman bahasa dan akses ke basis pengetahuan eksternal agar jawaban yang dihasilkan tidak hanya fasih, tetapi juga dapat dipertanggungjawabkan secara evidensial (Gao et al., 2024; Ji et al., 2024).

2.1.2 Penelitian Retrieval pada Sistem Question Answering

Dalam sistem question answering terbuka, kualitas jawaban sangat bergantung pada kualitas retrieval dokumen. Penelitian bertujuan meningkatkan ketepatan retrieval melalui Dense Passage Retrieval (DPR) berbasis dual-encoder. Metode ini memetakan query dan passage ke ruang embedding yang sama, lalu menilai relevansi berdasarkan kesamaan vektor. Hasil penelitian menunjukkan peningkatan retrieval top-20 sebesar 9–19% absolut dibanding BM25 pada beberapa benchmark QA, yang mengindikasikan bahwa retrieval semantik mampu menangkap keterkaitan makna meskipun tidak ada kecocokan kata yang persis (Karpukhin et al., 2020).

Di sisi lain, pendekatan sparse retrieval seperti BM25 tetap memiliki nilai

penting, terutama pada domain yang menuntut presisi terminologi. BM25 dirancang untuk mengukur relevansi berdasarkan distribusi istilah dan panjang dokumen, sehingga efektif ketika query memuat istilah hukum yang eksplisit dan normative. Dengan demikian, studi retrieval menunjukkan bahwa pendekatan semantik dan keyword-based memiliki karakter keunggulan berbeda, sehingga pemilihan metode retrieval tidak dapat disederhanakan menjadi satu pendekatan universal untuk semua domain.

2.1.3 Penelitian Re-ranking sebagai Penguat Tahap Retrieval

Selain retrieval awal, kualitas konteks juga ditentukan oleh tahap pemeringkatan ulang (re-ranking).Meneliti penggunaan BERT untuk passage re-ranking dengan tujuan meningkatkan urutan dokumen paling relevan pada posisi teratas. Metode ini bekerja dengan menilai ulang kandidat hasil retriever awal berdasarkan pasangan query-passage secara lebih mendalam. Hasil penelitian memperlihatkan bahwa re-ranking berbasis model bahasa kontekstual memberikan peningkatan signifikan dibanding strategi ranking tradisional (Nogueira & Cho, 2020).

Implikasi penting dari studi ini adalah bahwa performa QA tidak hanya ditentukan oleh kemampuan menemukan dokumen relevan, tetapi juga oleh kemampuan sistem memprioritaskan dokumen paling tepat untuk proses pembangkitan jawaban. Pada konteks regulasi lahan sawit yang memiliki banyak dokumen serupa secara topik, tahap ranking menjadi kritikal karena perbedaan kecil dalam pemeringkatan dapat menghasilkan jawaban dengan dasar hukum yang berbeda.

2.1.4 Penelitian Retrieval-Augmented Generation (RAG)

Lewis et al. (2020) memperkenalkan Retrieval-Augmented Generation (RAG) untuk menyelesaikan tugas NLP intensif pengetahuan. Tujuan penelitian ini adalah mengatasi keterbatasan model generatif murni yang hanya mengandalkan pengetahuan parametrik internal. Metode RAG menggabungkan retriever eksternal dan generator neural, sehingga model menghasilkan jawaban berdasarkan konteks

dokumen yang diambil saat inferensi. Hasil penelitian menunjukkan peningkatan performa pada beberapa tugas knowledge-intensive QA dibanding model tanpa retrieval (Lewis et al., 2020).

Kontribusi RAG menjadi sangat relevan untuk domain regulasi karena jawaban hukum tidak cukup benar secara linguistik, tetapi juga harus terikat pada sumber dokumen resmi. Literatur terbaru juga menunjukkan bahwa efektivitas RAG sangat dipengaruhi oleh kualitas chunking, indexing, retrieval, dan context construction, bukan hanya kapasitas model generative (Gao et al., 2024). Artinya, kualitas sistem QA regulasi merupakan hasil orkestrasi pipeline end-to-end, bukan hasil satu komponen tunggal.

2.1.5 Penelitian Evaluasi Retrieval Lintas Domain

Penelitian melalui benchmark BEIR mengevaluasi generalisasi berbagai metode retrieval pada beragam dataset dan domain. Tujuan utamanya adalah melihat konsistensi performa model retrieval di luar domain pelatihan. Hasil penelitian menunjukkan bahwa tidak ada pendekatan yang unggul absolut pada semua domain; dense retrieval dapat sangat kuat pada beberapa skenario, sementara sparse retrieval tetap kompetitif pada skenario lain (Thakur et al., 2021).

Temuan ini memberi implikasi metodologis penting bagi penelitian regulasi: karena dokumen hukum memiliki karakter khusus (teks panjang, struktur formal, istilah normatif), pendekatan retrieval perlu dirancang adaptif terhadap domain. Dengan kata lain, desain hybrid retrieval menjadi pilihan rasional karena berupaya menggabungkan kekuatan pencarian semantik dan ketepatan pencocokan istilah.

2.2 Dasar Teori

2.2.1 Kecerdasan Buatan (Artificial Intelligence)

Kecerdasan buatan merupakan bidang ilmu yang berfokus pada perancangan sistem komputasi agar mampu melakukan tugas yang membutuhkan kemampuan kognitif manusia, seperti penalaran, pengambilan keputusan, dan pemrosesan bahasa. Dalam konteks penelitian ini, AI menjadi kerangka umum yang menaungi komponen

retrieval dan generatif pada sistem tanya jawab regulasi lahan sawit. Perkembangan AI modern ditandai oleh meningkatnya kapasitas model berbasis arsitektur Transformer yang memungkinkan pemrosesan informasi tekstual berskala besar secara lebih efektif dibanding pendekatan sebelumnya (Vaswani et al., 2017). Dengan fondasi tersebut, sistem tanya jawab tidak lagi sekadar mencocokkan kata, tetapi dapat memodelkan makna pertanyaan serta keterkaitannya dengan dokumen regulasi secara lebih kontekstual.

2.2.2 Pemrosesan Bahasa Alami (Natural Language Processing)

Pemrosesan bahasa alami (NLP) adalah cabang AI yang mempelajari bagaimana sistem komputer memahami, merepresentasikan, dan menghasilkan bahasa manusia. Pada domain regulasi, NLP berperan penting karena dokumen hukum memiliki karakteristik kalimat panjang, terminologi formal, serta struktur normatif yang kompleks. Perkembangan model pra-latih seperti BERT memperlihatkan bahwa representasi kontekstual dua arah mampu meningkatkan performa pada berbagai tugas NLP, termasuk question answering (Devlin et al., 2019). Oleh karena itu, penerapan NLP pada penelitian ini berfungsi sebagai fondasi untuk memahami pertanyaan pengguna, merepresentasikan isi pasal regulasi, dan menjaga konsistensi makna antara query dan dokumen sumber.

2.2.3 Large Language Model (LLM)

Large Language Model adalah model bahasa berparameter besar yang dilatih pada korpus masif untuk mempelajari pola linguistik dan pengetahuan umum. Kemampuan LLM dalam menghasilkan teks yang koheren dan responsif mendorong penggunaannya pada berbagai aplikasi tanya jawab (Brown et al., 2020). Namun, dalam domain hukum/regulasi, penggunaan LLM secara mandiri berisiko menghasilkan jawaban yang tidak terverifikasi sumbernya (hallucination), sehingga memerlukan mekanisme grounding berbasis dokumen resmi (Ji et al., 2024). Dengan demikian, pada penelitian ini LLM diposisikan sebagai komponen generatif yang bekerja setelah proses retrieval, bukan sebagai satu-satunya sumber pengetahuan.

2.2.4 Sistem Tanya Jawab (Question Answering System)

Sistem tanya jawab adalah sistem yang dirancang untuk menerima pertanyaan dalam bahasa alami dan mengembalikan jawaban yang relevan, akurat, serta sesuai konteks. Dalam evolusi mutakhir, sistem QA modern tidak hanya mengandalkan model generatif, tetapi juga bergantung pada kualitas tahap retrieval untuk memilih konteks terbaik sebelum jawaban dibentuk. Pada domain regulasi lahan sawit, sistem QA ideal harus mampu: (1) memahami intent pertanyaan, (2) menemukan pasal relevan lintas dokumen, (3) menyusun jawaban yang dapat ditelusuri sumber hukumnya. Kebutuhan ini menegaskan bahwa QA pada domain regulasi termasuk kategori knowledge-intensive QA yang menuntut integrasi retrieval dan generation secara ketat (Lewis et al., 2020).

2.2.5 Information Retrieval: Sparse dan Dense Retrieval

Information Retrieval (IR) merupakan proses menemukan dokumen atau potongan teks yang relevan terhadap suatu query. Secara umum, terdapat dua pendekatan utama dalam penelitian ini, yaitu sparse retrieval (berbasis kata kunci) dan dense retrieval (berbasis embedding semantik). Dense retrieval seperti DPR efektif menangkap kesamaan makna ketika pertanyaan dan dokumen memiliki variasi leksikal (Karpukhin et al., 2020). Sebaliknya, sparse retrieval tetap penting untuk domain regulasi karena mampu mempertahankan presisi pada istilah hukum yang eksplisit. Hasil benchmark lintas domain menunjukkan tidak ada satu pendekatan yang selalu unggul absolut; performa sangat dipengaruhi karakter korpus dan tipe query (Thakur et al., 2021). Temuan ini menjadi dasar pemilihan strategi retrieval hibrida pada penelitian.

2.2.6 Passage Re-ranking

Re-ranking adalah tahap pemeringkatan ulang kandidat dokumen setelah retrieval awal untuk meningkatkan kualitas konteks teratas. Konsep ini penting karena kesalahan urutan kandidat dapat menurunkan kualitas jawaban walaupun dokumen relevan sebenarnya sudah ditemukan. Pendekatan re-ranking berbasis BERT terbukti mampu meningkatkan relevansi hasil pencarian secara konsisten

dibandingkan ranking tradisional (Nogueira & Cho, 2020). Dalam sistem tanya jawab regulasi, re-ranking berfungsi memastikan pasal dengan relevansi tertinggi diprioritaskan agar jawaban akhir lebih tepat sasaran dan mengurangi noise konteks.

2.2.7 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation adalah arsitektur yang menggabungkan proses pencarian dokumen relevan dengan pembangkitan jawaban oleh model generatif. Secara konseptual, RAG bekerja melalui alur: query pengguna → retrieval konteks → penyusunan prompt berbasis konteks → generasi jawaban. Keunggulan utamanya adalah peningkatan factual grounding karena jawaban ditopang oleh dokumen yang diambil saat inferensi (Lewis et al., 2020). Survei terkini menegaskan bahwa keberhasilan RAG tidak hanya bergantung pada model generatif, tetapi juga kualitas chunking, indexing, retrieval, dan konstruksi konteks (Gao et al., 2024). Oleh sebab itu, penelitian ini menempatkan desain pipeline retrieval sebagai komponen kunci, bukan sekadar pelengkap.

2.2.8 Hybrid Retrieval

Hybrid retrieval merupakan pendekatan penggabungan sparse retrieval dan dense retrieval untuk memperoleh keseimbangan antara ketepatan istilah dan pemahaman semantik. Pada domain regulasi, pendekatan ini relevan karena pertanyaan pengguna dapat mengandung istilah formal tertentu (misalnya jenis izin, nomenklatur regulasi) sekaligus parafrase yang memerlukan pemahaman makna. Integrasi keduanya diharapkan dapat meningkatkan recall dokumen relevan sekaligus menjaga precision pada konteks hukum. Secara metodologis, pemilihan hybrid retrieval juga sejalan dengan hasil evaluasi lintas domain yang menunjukkan perlunya kombinasi strategi retrieval sesuai karakter data (Karpukhin et al., 2020; Thakur et al., 2021).

2.2.9 Metadata Filtering pada Dokumen Regulasi

Metadata filtering adalah mekanisme penyaringan dokumen berdasarkan atribut terstruktur, seperti jenis regulasi, tahun terbit, dan instansi penerbit. Pada

korpus regulasi lahan sawit yang heterogen, metadata filtering berfungsi mempersempit ruang pencarian sehingga retrieval lebih fokus terhadap konteks normatif pertanyaan. Dalam perspektif desain RAG modern, strategi penyaringan konteks sebelum generation merupakan salah satu faktor penting yang memengaruhi kualitas jawaban akhir (Gao et al., 2024). Dengan demikian, metadata filtering pada penelitian ini tidak diposisikan sebagai fitur tambahan, melainkan sebagai komponen inti untuk meningkatkan relevansi dan keterlacakan jawaban.

2.2.10 Landasan Evaluasi Sistem QA Berbasis RAG

Evaluasi sistem tanya jawab berbasis RAG perlu mencakup dua lapisan utama: (1) kualitas retrieval, dan (2) kualitas jawaban generatif. Pada lapisan retrieval, evaluasi menilai apakah dokumen yang diambil benar-benar relevan dengan pertanyaan. Pada lapisan generatif, evaluasi menilai kesesuaian isi jawaban terhadap konteks yang diberikan serta konsistensi sumber rujukan. Dalam domain hukum, dimensi factuality menjadi sangat penting mengingat risiko hallucination pada LLM (Ji et al., 2024). Oleh karena itu, penelitian ini menempatkan evaluasi tidak hanya pada kefasihan jawaban, tetapi juga pada relevansi dokumen, ketepatan konteks, dan keandalan rujukan regulasi.

2.3 Kerangka Pemikiran

Kerangka pemikiran penelitian ini disusun berdasarkan kesenjangan antara kebutuhan pengguna terhadap informasi regulasi lahan sawit yang cepat dan akurat dengan keterbatasan pendekatan pencarian konvensional maupun model generatif yang tidak berbasis dokumen resmi. Dalam praktiknya, regulasi lahan sawit tersebar pada berbagai jenis peraturan dengan struktur substansi yang panjang, terminologi formal, dan hubungan norma yang saling terkait. Kondisi tersebut menyebabkan proses penelusuran secara manual menjadi tidak efisien dan berisiko menimbulkan ketidaktepatan interpretasi. Di sisi lain, sistem berbasis keyword semata cenderung sensitif terhadap kemiripan kata, tetapi belum tentu mampu menangkap maksud semantik pertanyaan secara utuh. Sementara itu, penggunaan Large Language Model tanpa proses retrieval berpotensi menghasilkan jawaban yang tidak memiliki landasan

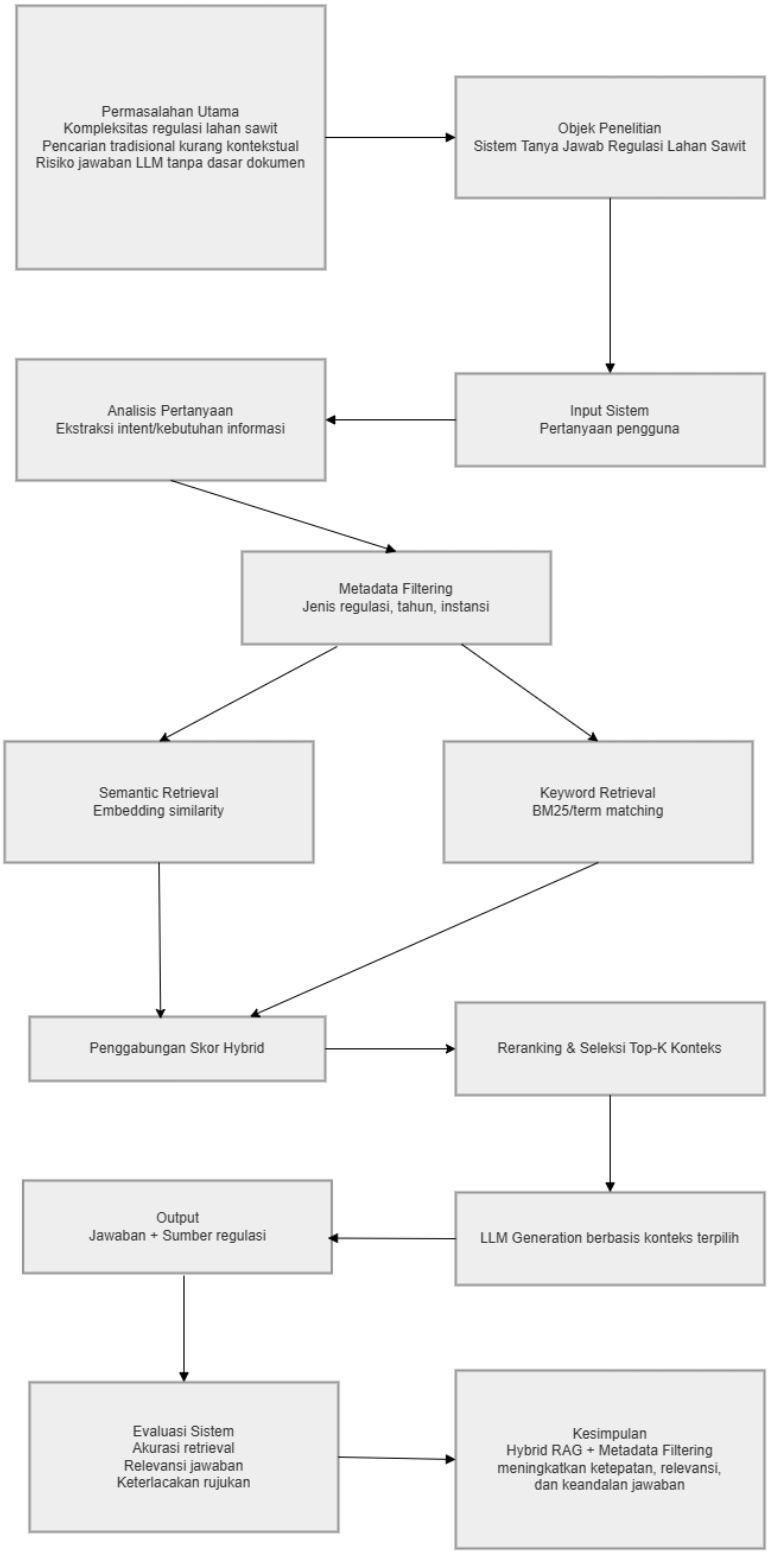
sumber yang jelas.

Berdasarkan masalah tersebut, penelitian ini membangun kerangka pemikiran yang menempatkan kualitas temu-kembali informasi sebagai prasyarat utama kualitas jawaban. Premis pertama dalam kerangka ini adalah bahwa jawaban yang dihasilkan model generatif sangat ditentukan oleh mutu konteks yang diberikan. Premis kedua adalah bahwa mutu konteks akan meningkat apabila retrieval tidak hanya bergantung pada satu pendekatan, melainkan menggabungkan pencarian semantik dan pencarian berbasis kata kunci. Premis ketiga adalah bahwa relevansi konteks dapat ditingkatkan lebih jauh melalui metadata filtering agar ruang pencarian dipersempit sesuai karakter pertanyaan, misalnya berdasarkan jenis regulasi, tahun terbit, dan instansi penerbit.

Secara operasional, alur berpikir penelitian dimulai dari pertanyaan pengguna sebagai input utama. Pertanyaan tersebut dianalisis untuk mengekstraksi indikasi kebutuhan informasi, kemudian digunakan untuk mengaktifkan metadata filtering pada korpus regulasi. Setelah ruang pencarian dipersempit, sistem menjalankan hybrid retrieval melalui dua jalur: semantic retrieval untuk menangkap kedekatan makna dan keyword retrieval untuk menjaga ketepatan istilah hukum. Hasil dari kedua jalur digabungkan menjadi kandidat konteks terbaik. Kandidat ini lalu diberikan kepada LLM untuk menghasilkan jawaban terstruktur yang selaras dengan sumber regulasi yang ditemukan. Dengan alur ini, sistem tidak hanya mengejar kefasihan bahasa, tetapi juga keterkaitan jawaban dengan evidensi dokumen.

Hubungan antarvariabel dalam penelitian ini dapat dipahami sebagai relasi kausal berjenjang. Variabel rekayasa pada tahap retrieval (hybrid scoring dan metadata filtering) diposisikan sebagai variabel penentu kualitas konteks. Kualitas konteks kemudian memengaruhi kualitas keluaran generatif, khususnya pada aspek relevansi jawaban, ketepatan substansi, dan keterlacakan rujukan hukum. Jika retrieval menghasilkan konteks yang kurang relevan, maka keluaran LLM berpotensi menyimpang; sebaliknya, jika retrieval tepat dan terfokus, maka kualitas jawaban meningkat. Dengan demikian, fokus evaluasi penelitian diarahkan untuk membuktikan bahwa peningkatan pada tahap retrieval benar-benar berkontribusi terhadap peningkatan kualitas jawaban secara end-to-end.

Dari sudut pandang metodologis, kerangka pemikiran ini menempatkan penelitian sebagai upaya integratif, bukan sekadar implementasi model tunggal. Kontribusi ilmiah yang dituju adalah pembuktian bahwa penggabungan semantic search, keyword retrieval, dan metadata filtering pada arsitektur Retrieval-Augmented Generation mampu menjawab kebutuhan domain regulasi lahan sawit yang kompleks. Kontribusi praktisnya adalah tersedianya sistem tanya jawab yang lebih cepat, relevan, dan dapat ditelusuri sumber regulasinya untuk mendukung pengguna dalam memahami ketentuan hukum secara lebih tepat. Oleh karena itu, kerangka pemikiran ini menjadi landasan logis bagi perancangan metode, skenario eksperimen, serta indikator evaluasi pada bab berikutnya.



Gambar 2. 1 Diagram Kerangka Pemikiran

1. Permasalahan Utama

Kotak ini menjelaskan dasar munculnya penelitian, yaitu adanya kompleksitas regulasi lahan sawit, pencarian informasi tradisional yang kurang kontekstual, serta risiko jawaban LLM tanpa dasar dokumen. Bagian ini menjadi titik awal karena menunjukkan adanya kebutuhan akan sistem yang lebih efektif dalam membantu pengguna memahami regulasi.

2. Objek Penelitian

Kotak ini menunjukkan fokus utama penelitian, yaitu sistem tanya jawab regulasi lahan sawit. Objek ini dipilih karena sistem tersebut diharapkan mampu membantu pengguna mendapatkan informasi regulasi secara lebih cepat, relevan, dan berbasis sumber dokumen resmi.

3. Input Sistem

Kotak ini menggambarkan masukan yang diterima sistem, yaitu pertanyaan dari pengguna. Pertanyaan tersebut menjadi pemicu utama untuk memulai proses penelusuran informasi di dalam sistem.

4. Analisis Pertanyaan

Pada tahap ini, pertanyaan pengguna dianalisis untuk mengidentifikasi kebutuhan informasi atau intent pertanyaan. Hasil analisis ini digunakan untuk menentukan konteks pencarian yang paling sesuai sebelum sistem melakukan proses retrieval.

5. Metadata Filtering

Kotak ini menunjukkan proses penyaringan dokumen berdasarkan metadata, seperti jenis regulasi, tahun, dan instansi. Tujuan tahap ini adalah mempersempit ruang pencarian agar sistem hanya mengambil dokumen yang paling relevan dengan pertanyaan pengguna.

6. Semantic Retrieval

Tahap ini melakukan pencarian dokumen berdasarkan kemiripan makna menggunakan embedding similarity. Proses ini penting untuk menangkap hubungan semantik antara pertanyaan pengguna dan isi dokumen regulasi, meskipun kata-katanya tidak persis sama.

7. Keyword Retrieval

Kotak ini menunjukkan proses pencarian berbasis kata kunci menggunakan BM25 atau term matching. Tahap ini digunakan untuk menemukan dokumen yang memiliki istilah hukum yang sama atau sangat mirip dengan pertanyaan pengguna.

8. Penggabungan Skor Hybrid

Setelah semantic retrieval dan keyword retrieval dilakukan, hasil keduanya digabungkan melalui perhitungan skor hybrid. Proses ini bertujuan menghasilkan peringkat dokumen yang lebih seimbang antara kesamaan makna dan kecocokan istilah.

9. Reranking dan Seleksi Top-K Konteks

Pada tahap ini, hasil gabungan disusun ulang berdasarkan skor terbaik, lalu dipilih beberapa konteks teratas (Top-K) yang akan digunakan sebagai bahan jawaban. Tahap ini memastikan hanya dokumen paling relevan yang diteruskan ke LLM.

10. LLM Generation berbasis konteks terpilih

Kotak ini menunjukkan proses pembangkitan jawaban oleh Large Language Model dengan menggunakan konteks yang telah dipilih sebelumnya. Dengan demikian, jawaban yang dihasilkan tidak berdiri sendiri, tetapi berbasis dokumen regulasi yang relevan.

11. Output

Output sistem berupa jawaban atas pertanyaan pengguna yang disertai sumber

regulasi. Bagian ini menunjukkan hasil akhir dari seluruh proses retrieval dan generasi jawaban.

12. Evaluasi Sistem

Kotak ini menjelaskan bahwa hasil sistem kemudian dievaluasi dari beberapa aspek, yaitu akurasi retrieval, relevansi jawaban, dan keterlacakan rujukan. Evaluasi dilakukan untuk menilai apakah metode yang diusulkan benar-benar bekerja dengan baik.

13. Kesimpulan

Kotak terakhir menunjukkan hasil akhir dari kerangka pemikiran, yaitu bahwa Hybrid RAG dengan metadata filtering dapat meningkatkan ketepatan, relevansi, dan keandalan jawaban. Kesimpulan ini menjadi dasar penegasan kontribusi penelitian terhadap penyelesaian masalah yang telah diidentifikasi pada awal diagram.

BAB III
METODE PENELITIAN

3.1 Jenis dan Pendekatan Penelitian

Penelitian ini termasuk dalam kategori penelitian rekayasa sistem (engineering research) yang berorientasi pada perancangan, pembangunan, dan pengujian sistem tanya jawab regulasi lahan sawit berbasis Hybrid Retrieval-Augmented Generation (Hybrid RAG) dan metadata filtering. Fokus utama penelitian rekayasa sistem pada kajian ini adalah menghasilkan artefak sistem yang dapat diimplementasikan, diuji secara terstruktur, dan dievaluasi performanya untuk menjawab kebutuhan pengguna terhadap akses informasi regulasi yang cepat, relevan, dan dapat ditelusuri sumber hukumnya.

Dari sisi proses, penelitian dilaksanakan melalui tahapan teknis yang sistematis, meliputi identifikasi kebutuhan, perancangan arsitektur, persiapan data regulasi, pengembangan modul retrieval dan generatif, integrasi komponen, serta pengujian kinerja sistem. Dengan demikian, luaran penelitian tidak terbatas pada model konseptual, tetapi mencakup sistem fungsional yang mampu menerima pertanyaan pengguna, melakukan penelusuran dokumen regulasi, dan menghasilkan jawaban berbasis evidensi dokumen.

Selain sebagai penelitian rekayasa sistem, studi ini juga menerapkan eksperimen evaluatif. Pendekatan eksperimen digunakan untuk menilai efektivitas metode yang diusulkan melalui perbandingan beberapa konfigurasi retrieval, yaitu pendekatan hybrid, semantic-only, dan keyword-only. Eksperimen dilakukan pada kumpulan pertanyaan uji yang merepresentasikan kebutuhan informasi regulasi lahan sawit, sehingga hasil evaluasi dapat menunjukkan kontribusi nyata dari kombinasi metode retrieval dan metadata filtering terhadap kualitas jawaban sistem.

Pendekatan analisis yang digunakan adalah kuantitatif, karena kinerja sistem diukur menggunakan indikator numerik yang terdefinisi secara operasional. Pengukuran kuantitatif diarahkan pada aspek ketepatan temu-kembali, relevansi

jawaban, kesesuaian jenis dokumen, serta konsistensi rujukan sumber yang digunakan sistem. Pendekatan kuantitatif ini dipilih agar proses penilaian bersifat objektif, terukur, dan dapat direplikasi.

Untuk memperkuat interpretasi hasil numerik, penelitian ini juga didukung oleh analisis deskriptif. Analisis deskriptif digunakan untuk menjelaskan pola hasil pengujian, mengidentifikasi kecenderungan performa tiap metode, serta menafsirkan faktor-faktor yang memengaruhi peningkatan atau penurunan kinerja sistem. Dengan kombinasi analisis kuantitatif dan deskriptif, penelitian ini diharapkan menghasilkan evaluasi yang tidak hanya menunjukkan nilai metrik, tetapi juga memberikan pemahaman yang komprehensif mengenai efektivitas pendekatan Hybrid RAG dan metadata filtering pada domain regulasi lahan sawit.

3.2 Objek Penelitian

Objek pada penelitian ini adalah pengembangan sistem tanya jawab regulasi lahan sawit berbasis Hybrid Retrieval-Augmented Generation (Hybrid RAG) dengan dukungan metadata filtering. Sistem dirancang untuk memproses pertanyaan pengguna dalam bahasa alami, menelusuri dokumen regulasi yang relevan melalui kombinasi pencarian semantik dan pencarian berbasis kata kunci, kemudian menghasilkan jawaban yang didasarkan pada konteks dokumen serta disertai rujukan sumber hukum. Dengan demikian, objek penelitian tidak hanya mencakup antarmuka tanya jawab, tetapi juga keseluruhan proses pengelolaan dokumen, retrieval, pembentukan konteks, dan generasi jawaban.

Pengguna sistem dalam penelitian ini adalah pihak yang membutuhkan akses cepat terhadap informasi regulasi lahan sawit, seperti mahasiswa, peneliti, praktisi, dan pemangku kepentingan terkait. Sistem diposisikan sebagai alat bantu penelusuran regulasi untuk meningkatkan efisiensi pencarian informasi, bukan sebagai pengganti pendapat hukum resmi. Oleh karena itu, setiap jawaban yang dihasilkan diarahkan untuk tetap terhubung dengan sumber regulasi yang digunakan, agar pengguna dapat melakukan verifikasi lanjutan pada dokumen asli.

Batas domain penelitian difokuskan pada regulasi Indonesia yang berkaitan dengan lahan dan perkebunan sawit, khususnya dokumen yang telah dikurasi dalam korpus

penelitian. Cakupan regulasi meliputi beberapa jenis peraturan, seperti Undang-Undang, Peraturan Pemerintah, Peraturan Presiden, dan Peraturan Menteri yang relevan dengan isu pertanahan, perkebunan, kehutanan, tata ruang, dan lingkungan. Pembatasan domain ini bertujuan agar pengembangan sistem tetap terarah, terukur, dan sesuai dengan tujuan penelitian.

Keluaran sistem pada penelitian ini mencakup: (1) jawaban atas pertanyaan pengguna, (2) daftar sumber regulasi yang dirujuk, (3) informasi metadata yang digunakan pada proses filtering, dan (4) informasi pendukung evaluasi retrieval. Ruang lingkup tersebut menegaskan bahwa penelitian berfokus pada peningkatan relevansi dan ketepatan jawaban berbasis dokumen resmi, sekaligus menjaga keterlacakan sumber sebagai unsur penting dalam domain regulasi.

Tabel 3. 1 Ruang Lingkup Objek Penelitian

Komponen	**Deskripsi Ruang Lingkup**
Objek utama	Sistem tanya jawab regulasi lahan sawit berbasis Hybrid RAG dan metadata filtering
Fokus sistem	Penelusuran dokumen relevan, pembentukan konteks, dan generasi jawaban berbasis LLM
Pengguna	Mahasiswa, peneliti, praktisi, dan pemangku kepentingan yang memerlukan informasi regulasi
Domain kajian	Regulasi lahan/perkebunan sawit di Indonesia
Cakupan dokumen	Regulasi terkurasi (misalnya UU, PP, Perpres, Permen terkait)
Input sistem	Pertanyaan pengguna dalam bahasa alami
Proses inti	Metadata filtering, hybrid retrieval, context construction, generation
Output sistem	Jawaban, sumber regulasi, metadata terkait, dan data pendukung evaluasi
Batas penggunaan	Sistem sebagai alat bantu informasi, bukan keputusan hukum final

3.3 Data Penelitian

Data penelitian pada studi ini berupa dokumen regulasi lahan sawit dan regulasi pendukung yang relevan dengan aspek pertanahan, kehutanan, perkebunan, tata ruang, dan lingkungan di Indonesia. Sumber data utama berasal dari dokumen peraturan resmi yang dikumpulkan dalam format PDF, kemudian diproses menjadi korpus teks terstruktur untuk kebutuhan retrieval dan pembangkitan jawaban.

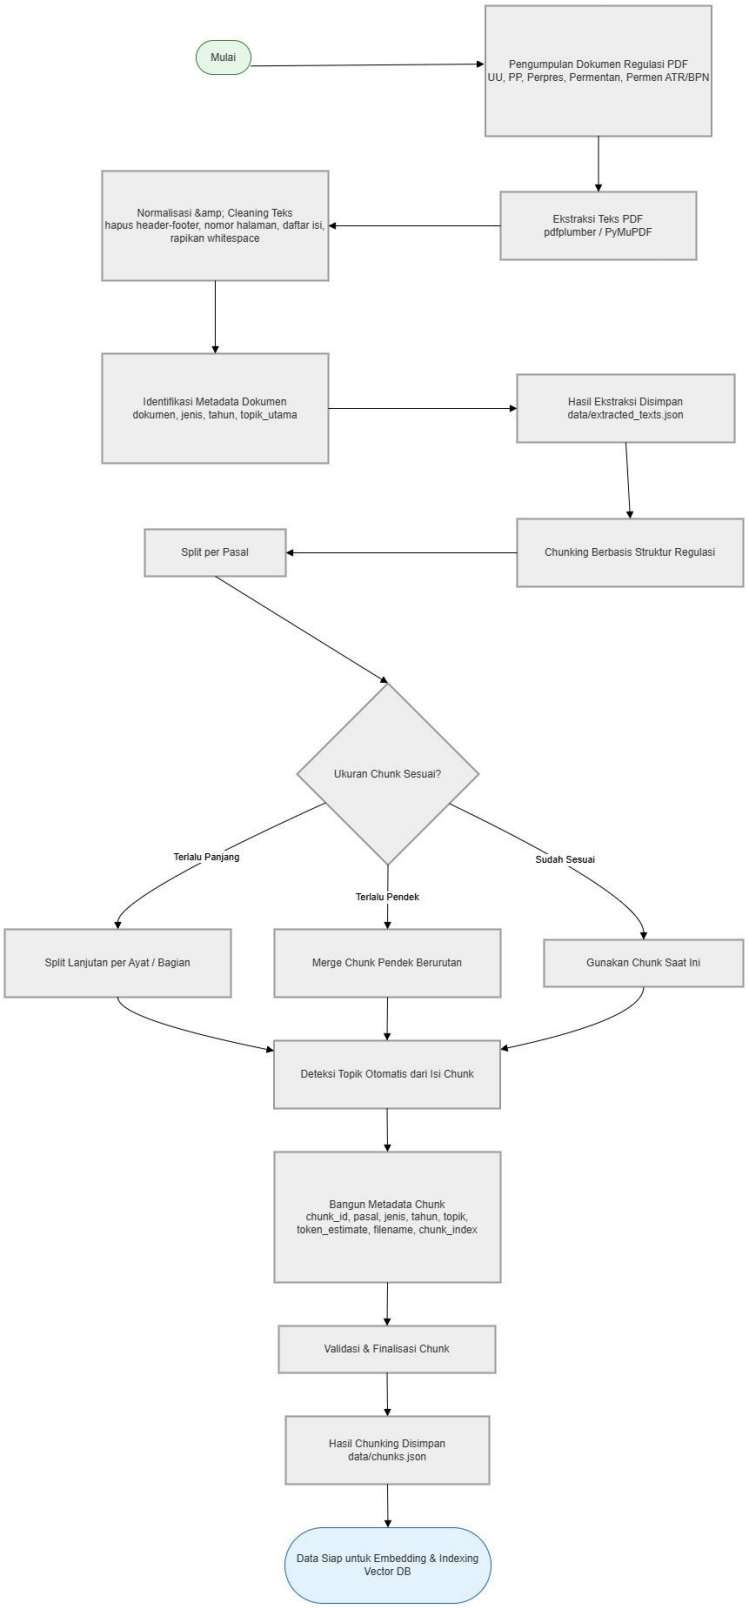
Proses pengumpulan data dilakukan melalui tiga tahap. Tahap pertama adalah akuisisi dokumen, yaitu menghimpun dokumen regulasi dari sumber resmi dan menyimpannya dalam satu repositori data. Tahap kedua adalah seleksi dokumen, yakni memilih hanya regulasi yang memiliki keterkaitan substansial dengan isu lahan sawit, termasuk jenis peraturan yang relevan (UU, PP, Perpres, Permen, dan dokumen pendukung lain yang masih terkait). Tahap ketiga adalah validasi data, yang mencakup pengecekan keterbacaan PDF, kesesuaian metadata dasar (nama dokumen, jenis, tahun), serta verifikasi hasil ekstraksi teks agar dapat diproses pada tahap chunking dan indexing.

Tabel 3. 2 Daftar Dokumen Regulasi yang Digunakan

No	Nama Dokumen	Jenis	Tahun
1	PP No. 3 Tahun 2022 (salinan)	PP	2022
2	PP No. 3 Tahun 2022	PP	2022

Tabel 3. 3 Statistik Data Penelitian

Indikator	Nilai
Jumlah dokumen regulasi	27
Jumlah total chunk hasil pemrosesan	3.126
Jumlah pasangan unik dokumen–pasal/bagian	1.940



Gambar 3. 1 Alur Pengumpulan dan Persiapan Data

3.3.1 Identifikasi Kebutuhan Data Regulasi

Tahap awal dalam persiapan data adalah mengidentifikasi jenis regulasi yang relevan dengan domain penelitian, yaitu tata kelola lahan sawit di Indonesia. Penulis menentukan kriteria inklusi data mencakup regulasi primer seperti Undang-Undang hingga regulasi teknis seperti Peraturan Menteri guna memastikan sistem memiliki basis pengetahuan yang komprehensif. Identifikasi ini juga melibatkan pemetaan topik-topik krusial seperti izin usaha, hak guna usaha, sertifikasi ISPO, hingga aspek perlindungan lingkungan hidup yang sering menjadi pertanyaan inti bagi para pemangku kepentingan di sektor perkebunan sawit.

3.3.2 Pengumpulan Dokumen Regulasi (PDF)

Penulis melakukan pengumpulan dokumen dalam format PDF melalui berbagai portal resmi digital milik pemerintah seperti Jaringan Dokumentasi dan Informasi Hukum (JDIH). Dokumen-dokumen ini mencakup berbagai hirarki peraturan mulai dari Undang-Undang (UU), Peraturan Pemerintah (PP), Peraturan Presiden (Perpres), hingga Peraturan Menteri (Permen). Kumpulan file PDF ini bertindak sebagai basis data mentah yang nantinya akan ditransformasi menjadi representasi digital yang dapat diolah oleh sistem guna menjamin bahwa setiap jawaban yang dihasilkan memiliki landasan hukum yang sah dan faktual.

3.3.3 Seleksi Dokumen Relevan

Koleksi dokumen yang telah terkumpul kemudian melalui proses seleksi manual yang ketat untuk memastikan relevansi terhadap ruang lingkup penelitian. Penulis hanya menyertakan regulasi yang memiliki kaitan substansial dengan ekosistem kelapa sawit, misalnya regulasi mengenai batasan luas lahan, tata cara peremajaan tanaman (replanting), hingga mekanisme sanksi administratif bagi pelanggar izin perkebunan. Dokumen yang dianggap terlalu umum atau tidak memiliki keterkaitan langsung dengan isu lahan sawit dikeluarkan dari korpus penelitian untuk menjaga efisiensi

proses indexing dan akurasi retrieval.

3.3.4 Validasi Dokumen

Validasi dilakukan untuk memeriksa integritas fisik dan digital dari setiap berkas PDF. Penulis memastikan file tidak dalam kondisi rusak (corrupt) dan teks di dalamnya bukan merupakan hasil pemindaian gambar (image-based PDF) yang tidak dapat dibaca, melainkan file PDF berbasis teks yang siap diekstraksi. Selain itu, Penulis melakukan standardisasi penamaan file dan verifikasi metadata dasar seperti nomor peraturan, tahun penerbitan, dan instansi penerbit untuk memastikan identitas unik setiap regulasi terjaga dengan baik dalam basis data sistem.

3.3.5 Ekstraksi Teks dari PDF

Dokumen PDF yang telah lolos validasi kemudian diproses menggunakan modul ekstraktor teks otomatis dengan pemanfaatan pustaka pemrograman seperti pdfplumber atau PyMuPDF. Proses ini melibatkan konversi data biner dari file PDF menjadi rangkaian karakter teks (plain text) yang dapat dipahami secara komputasional. Ekstraksi dilakukan secara menyeluruh tanpa mengabaikan detail kecil, namun tetap mempertahankan urutan logis dari dokumen asli agar struktur paragraf dan kalimat tetap terjaga bagi kebutuhan analisis Natural Language Processing (NLP) selanjutnya.

3.3.6 Pembersihan Teks (Cleaning)

Teks mentah hasil ekstraksi biasanya masih mengandung elemen non-substansial atau noise yang terbawa dari tata letak PDF. Penulis menerapkan algoritma pembersihan untuk menghapus nomor halaman, header, footer, daftar isi, serta simbol-simbol teknis yang tidak memberikan nilai informasi bagi jawaban. Pembersihan ini sangat krusial agar context window pada Large Language Model (LLM) hanya terisi oleh informasi substansial dari regulasi, sehingga meminimalkan risiko halusinasi atau degradasi kualitas jawaban akibat adanya gangguan teks repetitif.

3.3.7 Chunking Dokumen per Pasal/Ayat

Berbeda dengan sistem RAG umum yang melakukan pemotongan teks berdasarkan jumlah karakter yang acak, Penulis menerapkan strategi chunking berbasis struktur hukum yang presisi. Dokumen dibagi menjadi unit-unit kecil berdasarkan Pasal atau Ayat menggunakan pola ekspresi reguler (regex). Pendekatan ini memastikan bahwa setiap unit informasi (chunk) tetap utuh secara makna hukum, memudahkan sistem dalam merujuk sumber secara spesifik, dan memastikan bahwa tidak ada paragraf hukum yang terpotong di tengah kalimat yang dapat mengakibatkan misinterpretasi konteks oleh AI.

3.3.8 Penambahan Metadata

Setiap unit teks (chunk) yang dihasilkan kemudian diperkaya dengan metadata yang bersifat deskriptif dan operasional. Metadata ini mencakup nama lengkap dokumen, jenis peraturan, tahun, nomor pasal, serta klasifikasi topik otomatis (seperti "Izin", "Hutan", atau "Sertifikasi"). Penambahan metadata ini memungkinkan sistem untuk menjalankan fitur metadata filtering yang bekerja secara cerdas dalam memfilter ruang pencarian sebelum proses retrieval dilakukan, sehingga meningkatkan kecepatan dan relevansi temuan dokumen secara signifikan.

3.3.9 Validasi Hasil Chunk dan Metadata

Setelah proses segmentasi dan anotasi selesai, Penulis melakukan verifikasi akhir terhadap integritas dataset yang dihasilkan. Proses ini bertujuan memastikan bahwa setiap chunk telah terhubung dengan metadata yang benar dan tidak terjadi kehilangan data selama proses transformasi dari PDF ke JSON. Validasi ini menjamin bahwa sistem akan selalu memberikan rujukan sumber yang akurat (traceable) ketika pengguna menanyakan dasar hukum tertentu, serta memastikan format data telah sesuai dengan skema input yang dibutuhkan oleh database vektor dan indeks BM25.

3.3.10 Dataset Siap untuk Indexing dan Evaluasi

Tahap akhir dari persiapan data adalah penyimpanan korpus teks yang telah bersih dan terstruktur dalam format JSON. File ini bertindak sebagai "gold standard" yang siap digunakan untuk proses indexing ke Qdrant Vector Database melalui proses embedding, sekaligus diindeks ke dalam mesin pencarian leksikal BM25. Dengan tersedianya dataset yang matang ini, sistem siap memasuki fase operasional untuk melayani permintaan tanya jawab pengguna sekaligus menyediakan basis data yang konsisten untuk kebutuhan eksperimen dan evaluasi metrik kinerja sistem.

3.4 Tahapan Penelitian

Tahapan penelitian pada studi ini disusun secara sistematis untuk memastikan proses pengembangan sistem tanya jawab regulasi lahan sawit berlangsung terstruktur, terukur, dan dapat direplikasi. Alur penelitian dimulai dari penguatan landasan ilmiah melalui studi literatur, dilanjutkan dengan pengelolaan data regulasi, perancangan dan implementasi sistem berbasis Hybrid RAG, hingga evaluasi performa sistem secara eksperimen. Setiap tahap dirancang memiliki keterkaitan langsung antara input, proses, dan output sehingga kontribusi tiap tahap terhadap hasil akhir dapat dianalisis secara jelas.

Tahap pertama adalah studi literatur dan perumusan masalah, yaitu menelaah penelitian terdahulu terkait NLP, information retrieval, LLM, dan Retrieval-Augmented Generation untuk menentukan celah penelitian serta arah solusi. Tahap kedua adalah pengumpulan dan seleksi data regulasi, dengan fokus pada dokumen yang relevan terhadap lahan sawit. Tahap ketiga adalah validasi dan praproses data, meliputi ekstraksi teks dari PDF, pembersihan noise dokumen, segmentasi teks per pasal/ayat, serta penyusunan metadata dokumen.

Tahap keempat adalah pembangunan basis pencarian, yaitu pembentukan embedding untuk semantic retrieval, pembuatan indeks BM25 untuk keyword retrieval, serta penyimpanan data pada basis vektor. Tahap kelima

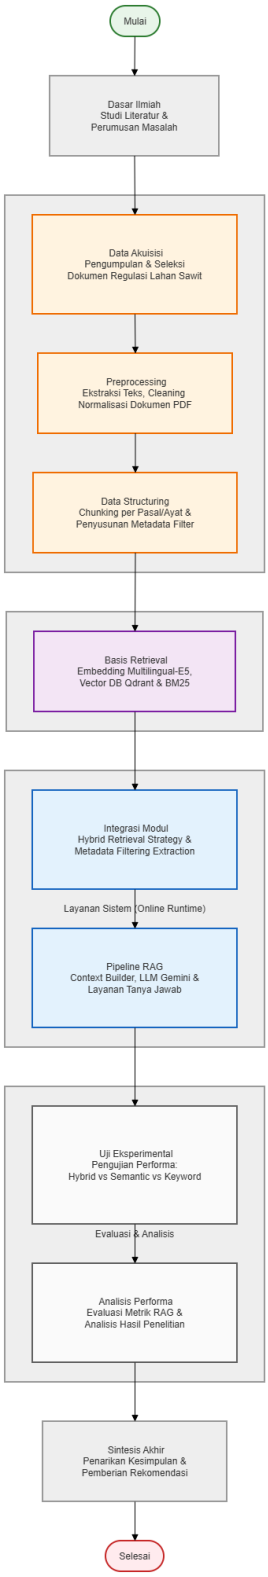
adalah perancangan dan integrasi modul sistem, mencakup hybrid retrieval, metadata filtering, konstruksi konteks, dan integrasi LLM pada pipeline RAG. Tahap keenam adalah pengujian sistem, dengan skenario pembanding antar metode retrieval (hybrid, semantic-only, BM25-only). Tahap ketujuh adalah evaluasi dan analisis hasil, yaitu menghitung metrik performa, membandingkan hasil antarmetode, dan menginterpretasikan temuan. Tahap terakhir adalah penarikan kesimpulan dan rekomendasi, yang merangkum efektivitas pendekatan yang diusulkan serta ruang pengembangan lanjutan.

Dengan struktur tahapan tersebut, penelitian tidak hanya menghasilkan artefak sistem, tetapi juga menyediakan kerangka evaluasi yang objektif untuk membuktikan pengaruh Hybrid RAG dan metadata filtering terhadap peningkatan relevansi dan keandalan jawaban regulasi.

Tabel 3. 4 Ringkasan Tiap Tahap Penelitian

No	Tahap	Input	Proses	Output
1	Studi literatur	Referensi ilmiah	Kajian teori dan identifikasi gap	Landasan konseptual penelitian
2	Perumusan penelitian	Hasil studi literatur	Menetapkan rumusan masalah, tujuan, batasan	Rancangan penelitian
3	Pengumpulan data	Sumber dokumen regulasi	Akuisisi dokumen PDF	Korpus awal dokumen
4	Seleksi dan validasi data	Korpus awal	Seleksi relevansi, cek keterbacaan dan kelengkapan	Korpus tervalidasi
5	Praproses data	Korpus tervalidasi	Ekstraksi, cleaning, normalisasi, chunking, metadata	Dataset siap indeks

6	Pembangunan basis retrieval	Dataset siap indeks	Embedding, indexing vector DB, indexing BM25	Basis retrieval siap pakai
7	Integrasi sistem	Basis retrieval + desain sistem	Integrasi hybrid retrieval, metadata filtering, LLM	Sistem QA terintegrasi
8	Pengujian dan evaluasi	Sistem terintegrasi + pertanyaan uji	Uji eksperimen dan perhitungan metrik	Hasil performa sistem
9	Analisis dan kesimpulan	Hasil evaluasi	Interpretasi hasil dan perumusan temuan	Kesimpulan penelitian dan rekomendasi



Gambar 3. 2 Flowchart Tahapan Penelitian End-to-End

3.4.1 Dasar Ilmiah (Studi Literatur & Perumusan Masalah)

Pada tahap awal penelitian, Penulis melaksanakan studi literatur secara komprehensif untuk membangun kerangka konseptual yang kokoh. Fokus kajian pustaka diarahkan pada perkembangan teknologi *Retrieval-Augmented Generation* (RAG) yang digabungkan dengan teknik *hybrid retrieval* untuk mengatasi limitasi *Large Language Model* (LLM) dalam hal data yang statis dan potensi halusinasi. Penulis menelaah berbagai jurnal ilmiah, dokumentasi teknis pustaka pemrograman, serta penelitian terdahulu mengenai optimasi *vector database* dan pembobotan *Reciprocal Rank Fusion* (RRF). Melalui tahap ini, Penulis berhasil mengidentifikasi celah penelitian pada spesifisitas domain regulasi hukum Indonesia yang memiliki struktur bahasa formal dan hierarkis, yang kemudian mendasari perumusan masalah mengenai bagaimana meningkatkan relevansi jawaban pada domain regulasi lahan sawit dengan bantuan *metadata filtering*.

3.4.2 Data Akuisisi (Pengumpulan & Seleksi Dokumen)

Tahap kedua berfokus pada penghimpunan aset data primer yang akan menjadi basis pengetahuan sistem. Penulis melakukan pengumpulan dokumen regulasi dalam format PDF dari situs-situs resmi pemerintah seperti JDIH dari berbagai kementerian terkait (Kementerian Pertanian, Kementerian ATR/BPN, serta KLHK). Koleksi data tersebut mencakup berbagai level hierarki hukum mulai dari Undang-Undang, Peraturan Pemerintah, hingga Peraturan Menteri. Setelah terkumpul, Penulis melakukan proses seleksi manual untuk memastikan bahwa setiap dokumen memiliki relevansi langsung dengan tata kelola lahan sawit, mencakup aspek perizinan, sertifikasi ISPO, konversi lahan, hingga aspek perlindungan lingkungan. Langkah ini sangat krusial agar korpus data yang terbentuk tidak terkontaminasi oleh informasi yang tidak relevan yang dapat mendegradasi kualitas *retrieval*.

3.4.3 Preprocessing (Ekstraksi, Cleaning & Normalisasi)

Setelah korpus dokumen terkumpul, Penulis melakukan proses *preprocessing* untuk mengubah data tidak terstruktur (PDF) menjadi format yang dapat diolah secara

komputasional. Penulis memanfaatkan pustaka *pdfplumber* dan *PyMuPDF* untuk mengekstraksi rangkaian teks mentah dari file PDF. Dalam proses ini, Penulis menghadapi tantangan *noise* seperti teks pada *header*, *footer*, nomor halaman, dan *watermark* yang sering kali mengganggu integritas makna kalimat. Oleh karena itu, Penulis menerapkan algoritma pembersihan teks untuk membuang elemen-elemen tersebut. Selain itu, Penulis melakukan normalisasi teks seperti konversi ke format UTF-8 yang seragam, penghapusan spasi berlebih, dan perbaikan karakter khusus hasil ekstraksi yang tidak sempurna guna memastikan konsistensi data sebelum masuk ke tahap analisis bahasa alami.

3.4.4 Data Structuring (Chunking & Penyusunan Metadata)

Penulis menyadari bahwa model bahasa memiliki batasan panjang konteks (*context window*), sehingga teks regulasi yang panjang harus dipecah menjadi unit informasi yang lebih kecil. Penulis menerapkan strategi *structural chunking* yang berorientasi pada struktur dokumen hukum Indonesia, yakni membagi teks berdasarkan unit Pasal dan Ayat menggunakan pola ekspresi reguler (*regex*). Pendekatan ini dipilih agar makna hukum dalam setiap potongan teks tetap utuh dan tidak terpotong di tengah kalimat. Bersamaan dengan proses ini, Penulis menyusun metadata secara sistematis untuk setiap *chunk*, yang mencakup identitas unik dokumen, nomor pasal, tahun terbit, jenis peraturan, dan label topik otomatis. Metadata ini nantinya akan berperan vital dalam fitur *filtering* yang memungkinkan sistem melakukan pra-seleksi dokumen berdasarkan kriteria spesifik sebelum proses pencarian vektor dilakukan.

3.4.5 Basis Retrieval (Embedding, Qdrant & BM25)

Pada tahap pembangunan basis pencarian, Penulis menerapkan pendekatan *hybrid indexing* untuk menangkap dua dimensi informasi: semantik dan leksikal. Penulis menggunakan model embedding *intfloat/multilingual-e5-small* untuk mengubah setiap unit teks (chunk) menjadi representasi vektor numerik yang menangkap kedalaman makna kata dalam konteks multibahasa. Vektor-vektor ini kemudian

disimpan dan diindeks ke dalam *Vector Database Qdrant*. Di sisi lain, Penulis juga membangun indeks leksikal berbasis algoritma *Best Matching 25* (BM25) untuk menangani kata kunci teknis hukum yang sering kali unik dan spesifik. Dengan tersedianya dua mekanisme indeks ini, sistem memiliki kemampuan ganda untuk memahami pertanyaan pengguna baik secara maknawi maupun secara harfiah kata kunci yang digunakan.

3.4.6 Integrasi Modul (Hybrid Retrieval & Metadata Filter)

Penulis melakukan integrasi seluruh komponen pencarian ke dalam satu modul orkestrasi *retrieval*. Inovasi utama pada tahap ini adalah penerapan *Metadata Extraction Filter*, di mana sistem secara otomatis menganalisis pertanyaan pengguna untuk mengekstrak parameter seperti tahun peraturan atau jenis peraturan tertentu. Parameter ini digunakan sebagai filter awal untuk mempersempit ruang pencarian dalam *database*, yang secara signifikan meningkatkan efisiensi komputasi. Setelah filter diterapkan, sistem menjalankan *hybrid searching* yang mengambil hasil dari *Qdrant* dan *BM25*, kemudian menggabungkan skor dari kedua metode tersebut menggunakan algoritma *Reciprocal Rank Fusion* (RRF). Proses ini memastikan bahwa dokumen yang muncul di urutan teratas adalah dokumen yang memang memiliki relevansi tinggi dari sudut pandang semantik maupun kesesuaian kata kunci.

3.4.7 Pipeline RAG (Context Builder, LLM & Tanya Jawab)

Pada tahap ini, Penulis membangun alur kerja *Retrieval-Augmented Generation* yang mengintegrasikan hasil pencarian dengan model bahasa besar. Penulis merancang komponen *Context Builder* yang bertugas menyeleksi Top-K hasil pencarian terbaik dan menyusunnya menjadi sebuah paket konteks yang rapi bersama instruksi khusus (*system prompt*). Konteks ini kemudian dikirimkan ke *Large Language Model* (LLM) melalui antarmuka API Gemini-2.0-Flash. Penulis menerapkan teknik *grounding* yang ketat, di mana LLM diinstruksikan untuk hanya memberikan jawaban

berdasarkan informasi yang ada dalam konteks yang diberikan dan dilarang menggunakan pengetahuan eksternal demi menghindari halusinasi rincian hukum. Hasil akhirnya adalah jawaban sistem yang tidak hanya akurat secara bahasa, tetapi juga memiliki landasan hukum yang dapat dipertanggungjawabkan.

3.4.8 Uji Eksperimental (Scenario Testing)

Sistem yang telah dibangun kemudian memasuki fase pengujian empiris. Penulis menyusun serangkaian skenario pengujian menggunakan kumpulan pertanyaan uji (query) yang dirancang untuk mewakili berbagai kompleksitas informasi regulasi lahan sawit. Penulis melakukan pengujian komparatif dengan membagi sistem ke dalam tiga konfigurasi berbeda: sistem yang hanya menggunakan pencarian semantik (*semantic-only*), sistem yang hanya menggunakan kata kunci (*BM25-only*), dan sistem usulan yang menggunakan *Hybrid RAG* dengan *metadata filtering*. Pengujian ini dilakukan secara sistematis untuk merekam performa sistem dalam kondisi yang bervariasi, guna mengumpulkan data primer yang akan digunakan pada tahap analisis metrik.

3.4.9 Analisis Performa (Evaluasi Metrik & Hasil)

Penulis melakukan analisis mendalam terhadap data hasil pengujian yang telah dikumpulkan. Penulis menghitung metrik performa sistem informasi konvensional seperti *Recall* untuk mengukur kelengkapan dokumen yang ditemukan, serta metrik relevansi jawaban LLM melalui proses anotasi atau evaluasi otomatis. Penulis juga menganalisis korelasi antara penerapan *metadata filtering* dengan peningkatan akurasi retrieval dibandingkan tanpa filter. Analisis deskriptif digunakan untuk menjelaskan mengapa kegagalan atau keberhasilan tertentu terjadi pada *query* yang bersifat ambigu. Hasil analisis ini memberikan gambaran objektif mengenai efektivitas metode yang diusulkan dan sejauh mana sistem mampu memenuhi standar akurasi yang dibutuhkan dalam domain regulasi.

3.4.10 Sintesis Akhir (Kesimpulan & Rekomendasi)

Tahap terakhir dalam perjalanan penelitian ini adalah melakukan sintesis menyeluruh atas seluruh temuan yang ada. Penulis merumuskan kesimpulan yang menjawab pertanyaan penelitian dan membuktikan hipotesis mengenai kontribusi positif strategi *Hybrid RAG* dan *metadata filtering* terhadap kualitas sistem tanya jawab regulasi. Penulis juga merefleksikan proses rekayasa sistem yang telah dilakukan untuk mengidentifikasi batasan-batasan teknis yang masih ada. Sebagai penutup, Penulis memberikan rekomendasi strategis bagi pengembang selanjutnya, seperti penambahan jenis regulasi yang lebih luas, integrasi model bahasa yang lebih mutakhir, atau pengembangan antarmuka pengguna yang lebih intuitif, sehingga penelitian ini dapat memberikan manfaat berkelanjutan bagi kemajuan teknologi informasi hukum di Indonesia.

3.5 Perancangan Sistem

Perancangan sistem pada penelitian ini disusun untuk memastikan proses tanya jawab regulasi lahan sawit berjalan secara terintegrasi, mulai dari penerimaan pertanyaan pengguna hingga penyajian jawaban berbasis sumber regulasi. Arsitektur yang digunakan menerapkan pendekatan modular agar setiap komponen memiliki fungsi yang jelas, mudah dievaluasi, dan dapat dikembangkan pada penelitian lanjutan. Secara konseptual, sistem dibangun dalam dua lapisan utama, yaitu lapisan persiapan data (offline) dan lapisan layanan tanya jawab (online runtime).

Pada lapisan offline, dokumen regulasi dikumpulkan, diekstraksi, dibersihkan, dipecah menjadi unit chunk per pasal/ayat, lalu diperkaya metadata (jenis regulasi, tahun, dokumen, pasal, topik). Data terstruktur ini kemudian diindeks ke dua mekanisme pencarian: basis vektor untuk semantic retrieval dan indeks BM25 untuk keyword retrieval. Pada lapisan online, sistem menerima pertanyaan pengguna, menerapkan metadata filtering, menjalankan hybrid retrieval, membangun konteks jawaban, lalu mengirim konteks tersebut ke LLM untuk menghasilkan jawaban akhir beserta sumber yang dirujuk. Melalui desain ini, kualitas jawaban tidak hanya

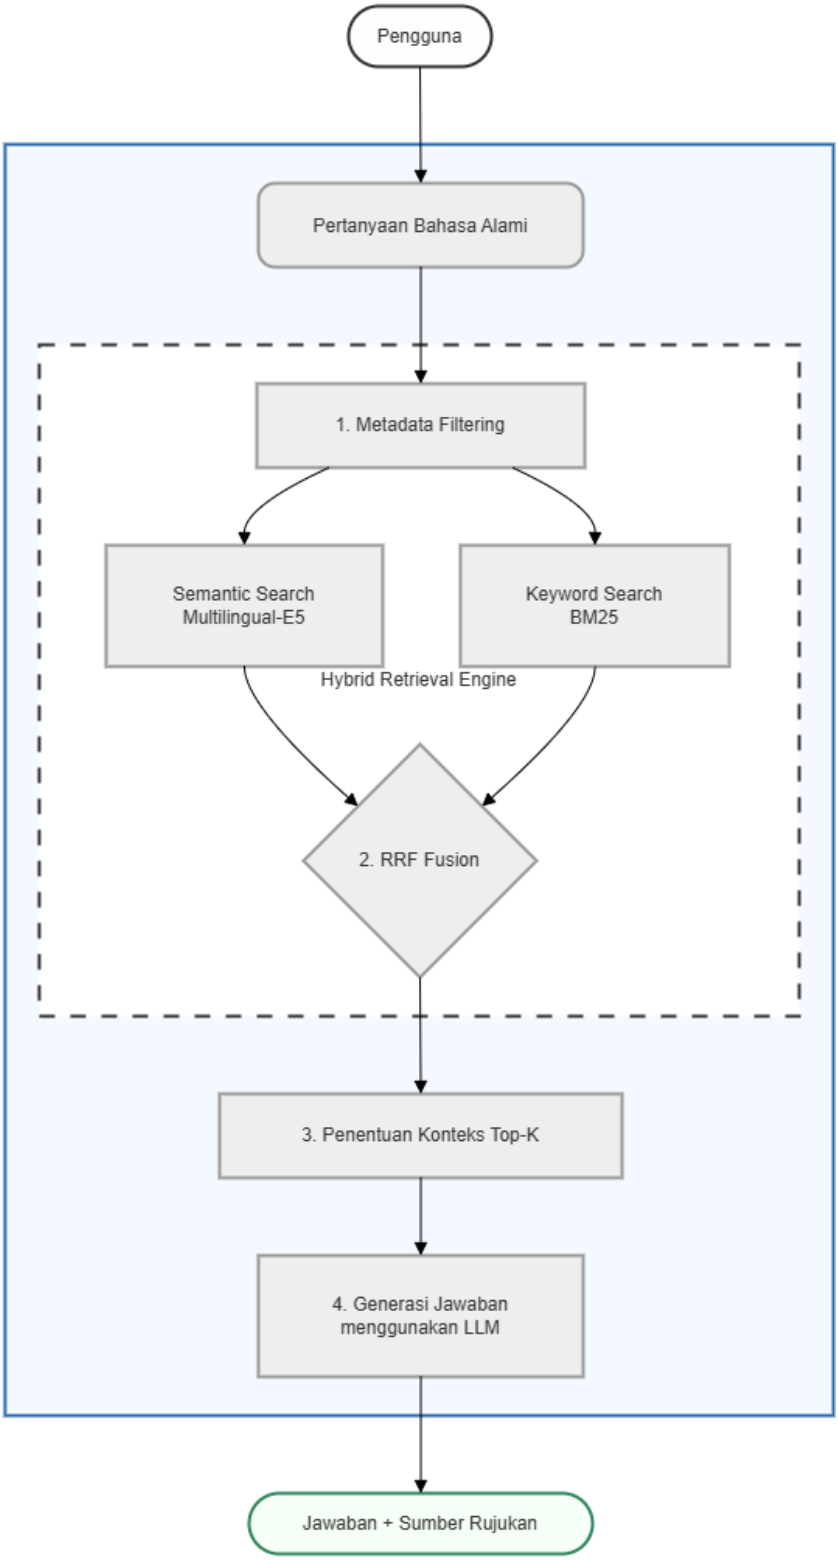
ditentukan oleh model generatif, tetapi terutama oleh kualitas konteks dokumen hasil retrieval.

Hubungan antar komponen dirancang dengan prinsip orkestrasi terpusat melalui pipeline RAG. Pipeline bertugas mengatur urutan eksekusi modul dan memastikan setiap tahap saling terhubung secara logis: validasi query, filter metadata, retrieval hibrida, ranking, context construction, generation, dan source mapping. Dengan pola ini, sistem dapat menjaga keseimbangan antara ketepatan istilah hukum (keyword retrieval) dan pemahaman semantik (semantic retrieval), sekaligus mempertahankan keterlacakan sumber jawaban.

Tabel 3. 5 Parameter Sistem

No	Modul	Fungsi Utama	Input	Output
1	Frontend Web	Menyediakan antarmuka tanya jawab dan menampilkan hasil	Pertanyaan pengguna	Request ke backend, tampilan jawaban
2	Backend API	Menangani request/response dan memanggil pipeline	Request dari frontend	Respons terstruktur JSON
3	Orkestrator RAG Pipeline	Mengatur urutan proses runtime end-to-end	Pertanyaan tervalidasi	Jawaban final dan sumber
4	Metadata Filtering	Membatasi ruang pencarian berdasarkan atribut regulasi	Query dan metadata indeks	Kandidat dokumen terfilter
5	Semantic Retrieval	Mengambil chunk berdasarkan kemiripan embedding	Query embedding, vector DB	Kandidat semantik + skor
6	Keyword Retrieval	Mengambil chunk berdasarkan kecocokan	Query tokenized,	Kandidat keyword + skor

	BM25	istilah	BM25 index	
7	Fusi Skor Hybrid	Menggabungkan skor semantic dan BM25	Skor dua retriever	Peringkat final kandidat
8	Context Builder	Menyusun konteks Top-K untuk prompt LLM	Kandidat teratas	Teks konteks terstruktur
9	LLM Generator	Menghasilkan jawaban berbasis konteks dokumen	Prompt sistem + konteks + pertanyaan	Jawaban teks
10	Source Mapping	Mencocokkan jawaban dengan sumber yang dirujuk	Jawaban dan daftar sumber retrieval	Daftar sumber rujukan final
11	PDF Extraction & Cleaning	Ekstraksi teks dan pembersihan noise dokumen	PDF regulasi	Teks bersih
12	Chunking & Metadata	Segmentasi pasal/ayat dan pemberian metadata	Teks bersih	Chunk terstruktur + metadata
13	Embedding & Vector Indexing	Konversi teks ke vektor dan penyimpanan indeks	Chunk terstruktur	Vector DB siap query
14	BM25 Indexing	Pembangunan indeks keyword untuk retrieval leksikal	Teks chunk	Indeks BM25 siap query



Gambar 3. 3 Pipeline Metode yang Diusulkan

3.5.1 Input Pertanyaan Bahasa Alami

Proses *runtime* sistem dimulai ketika pengguna memasukkan pertanyaan dalam bentuk bahasa alami (*natural language*) melalui antarmuka pengguna berbasis web. Pada tahap ini, sistem menerima string teks mentah yang merepresentasikan kebutuhan informasi spesifik pengguna terkait regulasi lahan sawit, misalnya mengenai tata cara perolehan Hak Guna Usaha (HGU) atau persyaratan sertifikasi ISPO. Pertanyaan ini menjadi data input utama yang bersifat dinamis dan tidak terstruktur. Penulis merancang sistem agar mampu menangani variasi semantik dalam kueri, sehingga pengguna tidak perlu menggunakan terminologi hukum yang kaku untuk mendapatkan informasi yang relevan.

3.5.2 Metadata Filtering (Extraction)

Setelah pertanyaan diterima, sistem menjalankan modul *Metadata Extraction* yang bekerja menggunakan algoritma pencocokan pola dan kamus entitas hukum. Modul ini bertugas mengidentifikasi parameter spesifik seperti tahun peraturan, jenis peraturan (UU, PP, Permen), atau topik hukum utama (seperti "Izin", "Hutan", atau "Sertifikasi") yang tersirat dalam kueri pengguna. Hasil ekstraksi ini ditransformasikan menjadi skema *filtering* yang diterapkan langsung pada *database* sebelum proses pencarian dilakukan. Dengan menerapkan filter di awal (*pre-filtering*), sistem secara drastis mempersempit ruang pencarian (*search space*) hanya pada dokumen yang memenuhi kriteria administratif, yang secara teoritis meningkatkan presisi dan mengurangi beban komputasi pada tahap retrieval semantik yang lebih berat.

3.5.3 Hybrid Retrieval (Semantic & Lexical Search)

Ruang pencarian yang telah terfilter kemudian diproses secara paralel oleh dua mesin pencari yang berbeda untuk menangkap dua dimensi relevansi yang berbeda. Jalur pertama adalah *Semantic Search* yang memanfaatkan model embedding *intfloat/multilingual-e5-small* untuk merepresentasikan makna kontekstual kueri ke dalam vektor numerik 384 dimensi, yang kemudian dicocokkan dengan vektor

dokumen di *Qdrant*. Jalur kedua adalah *Lexical Search* berbasis algoritma BM25 yang menghitung skor berdasarkan frekuensi dan keunikan kata kunci teknis. Kombinasi ini sangat krusial dalam domain hukum, di mana sistem harus mampu memahami maksud pertanyaan yang bersifat general (semantik) sekaligus tetap akurat dalam menemukan istilah-istilah hukum spesifik yang tidak memiliki sinonim (leksikal).

3.5.4 RRF Fusion (Scoring & Re-ranking)

Hasil dari kedua jalur pencarian (semantik dan leksikal) menghasilkan dua daftar kandidat dokumen yang memiliki skala skor berbeda dan tidak dapat dibandingkan secara langsung. Penulis menerapkan algoritma *Reciprocal Rank Fusion* (RRF) sebagai mekanisme penggabungan skor yang objektif tanpa memerlukan tuning bobot manual. RRF bekerja dengan memberikan bobot pada dokumen berdasarkan posisi peringkatnya (*rank*) di masing-masing metode menggunakan konstanta penyeimbang ($k=60$). Dokumen yang konsisten muncul di peringkat atas pada kedua metode akan mendapatkan skor gabungan tertinggi. Proses ini memastikan bahwa hasil akhir yang diberikan kepada tahap selanjutnya adalah dokumen yang memiliki soliditas baik dari sisi kedekatan makna maupun ketepatan kata kunci.

3.5.5 Penentuan Konteks Top-K

Setelah peringkat final terbentuk melalui RRF, sistem melakukan seleksi terhadap sejumlah K potongan teks (*chunks*) terbaik yang memiliki skor tertinggi untuk dijadikan sebagai konteks jawaban. Penulis menetapkan batasan jumlah Top-K yang dinamis untuk memastikan bahwa informasi yang dikirimkan ke model bahasa tetap padat dan relevan tanpa menyebabkan fenomena "*lost in the middle*" pada model bahasa. Potongan-potongan teks terpilih ini disusun secara kronologis atau berdasarkan relevansi skor untuk membentuk sebuah narasi konteks yang koheren. Tahap ini bertindak sebagai jembatan informasi yang memastikan bahwa LLM hanya bekerja dengan data yang benar-benar esensial dari korpus regulasi yang ada.

3.5.6 Generasi Jawaban menggunakan LLM

Konteks Top-K yang telah terpilih kemudian disisipkan ke dalam sebuah *template prompt* yang dirancang secara teliti (*prompt engineering*). Instruksi sistem (*system prompt*) memaksa model bahasa *Gemini-2.0-Flash* untuk berperan sebagai asisten legal virtual yang objektif. Konfigurasi ini mewajibkan model untuk melakukan sintesis informasi hanya dari teks konteks yang diberikan dan dilarang keras menggunakan pengetahuan internal model yang mungkin sudah kedaluwarsa. Penulis memanfaatkan kemampuan penalaran cepat dari Gemini-2.0-Flash untuk menghasilkan jawaban yang tidak hanya akurat secara faktual, tetapi juga menggunakan gaya bahasa formal yang sesuai dengan standar komunikasi hukum di Indonesia.

3.5.7 Jawaban dan Sumber Rujukan

Hasil akhir yang disajikan kepada pengguna adalah jawaban komprehensif yang disusun dalam format yang mudah dipahami. Fitur utama pada output ini adalah penyertaan rujukan sumber (sitasi) secara otomatis untuk setiap poin jawaban yang diberikan. Sistem memetakan metadata identitas dokumen (Nomor, Tahun, dan Pasal) yang melekat pada setiap *chunk* hasil retrieval ke dalam teks jawaban. Hal ini memberikan nilai transparansi tinggi bagi pengguna, memungkinkan verifikasi silang langsung ke dokumen asli, serta memastikan bahwa sistem memenuhi prinsip akuntabilitas informasi dalam konteks penyediaan data regulasi publik.

Tabel 3. 6 Atribut dan Aturan Metadata Filtering

Atribut Filter	**Cara Deteksi dari Query**	**Aturan Penerapan**
jenis	Kata kunci: UU, PP, Perpres,	Pencarian dibatasi pada jenis

	Permentan, Permen ATR	regulasi yang sama
topik	Kata kunci topik: sawit, hutan, izin, lingkungan, ISPO, sanksi, peremajaan, dll.	Kandidat diprioritaskan pada metadata topik yang mengandung topik terkait
tahun	Pola “tahun YYYY”	Pencarian dibatasi pada tahun yang sama
tahun_min	Pola rentang tahun awal	Filter (tahun \ge tahun_min)
tahun_max	Pola rentang tahun akhir	Filter (tahun \le tahun_max)

3.8 Lingkungan Implementasi

Lingkungan implementasi pada penelitian ini mencakup perangkat keras dan perangkat lunak yang digunakan untuk menjalankan seluruh tahapan sistem, mulai dari preprocessing dokumen regulasi, indexing, retrieval, hingga generasi jawaban. Implementasi dirancang agar dapat berjalan pada komputer pengembangan standar tanpa ketergantungan wajib pada GPU. Namun, penggunaan GPU tetap dapat meningkatkan kecepatan proses embedding dan inferensi model, terutama saat pemrosesan data berukuran besar.

Dari sisi perangkat keras, komponen utama yang memengaruhi kinerja sistem adalah prosesor, kapasitas RAM, media penyimpanan, dan konektivitas internet untuk akses API model. Dari sisi perangkat lunak, sistem dibangun menggunakan Python dengan dukungan framework backend, library NLP, library retrieval, dan basis data vektor. Seluruh komponen perangkat lunak dipilih berdasarkan kompatibilitas dengan pipeline Hybrid RAG dan kemudahan replikasi eksperimen.

Tabel 3. 7 Spesifikasi Hardware

Komponen	**Spesifikasi yang Digunakan/Disarankan**
Prosesor	Intel Core i5 Gen 12

(CPU)	
Memori (RAM)	8 GB
Penyimpanan	512 GB
GPU	Nvidia Geforce RTX 2050
Sistem Operasi	Windows 11 64-bit
Koneksi Internet	Diperlukan untuk akses API LLM dan sinkronisasi dependensi

Tabel 3. 8 Software, Framework, dan Library yang Digunakan

Kategori	**Tools/Library**	**Fungsi dalam Sistem**
Bahasa Pemrograman	Python 3.11	Implementasi seluruh pipeline sistem
Backend API	Flask, Flask-CORS	Menyediakan layanan API untuk query sistem
Frontend Web	HTML, CSS, JavaScript	Antarmuka pengguna berbasis web
Frontend Alternatif	Streamlit	Antarmuka uji/eksperimen cepat
PDF Processing	pdfplumber, PyMuPDF	Ekstraksi teks dari dokumen regulasi PDF
NLP Embedding	sentence-transformers	Pembentukan embedding teks regulasi
Embedding Model	intfloat/multilingual-e5-small	Representasi semantik untuk retrieval
Vector Database	Qdrant	Penyimpanan embedding dan semantic search

Keyword Retrieval	rank-bm25	Pencarian berbasis kata kunci (BM25)
LLM Client	openai (OpenRouter-compatible)	Integrasi model generatif untuk RAG
Data Processing	pandas, numpy	Pengolahan data dan analisis hasil
Evaluasi/ML Utility	scikit-learn	Dukungan evaluasi dan utilitas analitik
Environment	python-dotenv	Manajemen konfigurasi variabel lingkungan
Utility	tqdm	Monitoring progres proses pipeline

3.9 Teknik Analisis Hasil

Teknik analisis hasil pada penelitian ini digunakan untuk menafsirkan keluaran pengujian sistem Hybrid RAG secara terstruktur, objektif, dan sesuai dengan tujuan penelitian. Analisis dilakukan dengan membandingkan hasil pada beberapa skenario pengujian, yaitu hybrid retrieval, semantic-only retrieval, dan keyword-only retrieval (BM25). Hasil pengujian kemudian diinterpretasikan berdasarkan nilai metrik yang diperoleh, sehingga dapat diketahui sejauh mana sistem mampu menemukan dokumen yang relevan, menghasilkan jawaban yang sesuai konteks, dan menjaga keterlacakan sumber regulasi.

Cara interpretasi hasil dilakukan melalui dua pendekatan utama. Pertama, analisis kuantitatif, yaitu membandingkan nilai metrik evaluasi antar metode untuk melihat metode mana yang memberikan performa terbaik. Kedua, analisis deskriptif, yaitu menjelaskan kecenderungan hasil secara naratif, misalnya mengapa suatu metode memperoleh nilai lebih tinggi pada topik tertentu atau mengapa metadata filtering dapat memperbaiki relevansi retrieval. Dengan cara ini, hasil pengujian tidak hanya dibaca sebagai angka, tetapi juga dipahami secara substantif dalam konteks domain regulasi lahan sawit.

Indikator keberhasilan sistem ditentukan berdasarkan tiga aspek utama. Aspek pertama adalah kualitas retrieval, yang menunjukkan apakah dokumen atau chunk yang diambil sesuai dengan kebutuhan pertanyaan. Aspek kedua adalah relevansi jawaban, yang menunjukkan apakah jawaban yang dihasilkan LLM benar-benar selaras dengan konteks regulasi yang diberikan. Aspek ketiga adalah keandalan sumber, yang menunjukkan apakah jawaban dapat ditelusuri kembali ke dokumen regulasi yang valid. Sistem dianggap semakin baik apabila mampu memberikan nilai metrik yang tinggi pada ketiga aspek tersebut secara konsisten.

Secara operasional, hasil penelitian dinyatakan berhasil apabila metode Hybrid RAG menunjukkan performa yang lebih baik atau setidaknya lebih seimbang dibandingkan semantic-only dan BM25-only pada metrik retrieval dan relevansi jawaban. Selain itu, keberhasilan juga dilihat dari kemampuan sistem dalam mempertahankan konteks regulasi yang benar, menampilkan sumber yang sesuai, dan meminimalkan keluaran yang tidak relevan. Dengan demikian, analisis hasil dalam penelitian ini berfungsi untuk membuktikan efektivitas pendekatan yang diusulkan secara terukur dan dapat dipertanggungjawabkan.

Tabel 3. 9 Kriteria Interpretasi Nilai Metrik

Rentang Nilai	**Kategori**	**Interpretasi**
0.00 – 0.33	Rendah	Kinerja sistem masih kurang baik dan perlu peningkatan signifikan
0.34 – 0.66	Sedang	Kinerja sistem cukup, tetapi belum optimal
0.67 – 1.00	Tinggi	Kinerja sistem baik dan menunjukkan hasil yang kuat

DAFTAR PUSTAKA

Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., … Amodei, D. (2020). *Language Models are Few-Shot Learners*. https://commoncrawl.org/the-data/

Chalkidis, I., Fergadiotis, M., Malakasiotis, P., & Aletras, N. (2020). *Findings of the Association for Computational Linguistics LEGAL-BERT: The Muppets straight out of Law School*. http://www.legislation.gov.uk

Devlin, J., Chang, M.-W., Lee, K., Google, K. T., & Language, A. I. (2019). *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*. https://github.com/tensorflow/tensor2tensor

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). *Retrieval-Augmented Generation for Large Language Models: A Survey*. http://arxiv.org/abs/2312.10997

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y., Chen, D., Dai, W., Chan, H. S., Madotto, A., & Fung, P. (2024). *Survey of Hallucination in Natural Language Generation*. https://doi.org/10.1145/3571730

Karpukhin, V., Oˇ Guz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., Yih, W.-T., & Ai, F. (2020). *Dense Passage Retrieval for Open-Domain Question Answering*. https://github.com/facebookresearch/DPR.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*. https://github.com/huggingface/transformers/blob/master/

Nogueira, R., & Cho, K. (2020). *Passage Re-ranking with BERT*. http://arxiv.org/abs/1901.04085

Rajpurkar, P., Zhang, J., Lopyrev, K., & Liang, P. (2016). *SQuAD: 100,000+ Questions for Machine Comprehension of Text*. https://stanford-qa.com,

Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. https://github.com/UKPLab/

Thakur, N., Reimers, N., Rücklé, A., Srivastava, A., & Gurevych, I. (2021). *BEIR: A Heterogenous Benchmark for Zero-shot Evaluation of Information Retrieval Models*. http://arxiv.org/abs/2104.08663

Vaswani, A., Brain, G., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). *Attention Is All You Need*.